


مدخل إلى الذكاء الاصطناعي وتطبيقاته



الفهرس

4	المقدمة
5	مدخل إلى الذكاء الاصطناعي وتطبيقاته
2	بيانات الذكاء الاصطناعي
4	لماذا تستخدم المؤسسات أنواعاً مختلفة من البيانات
5	المصادر الشائعة للبيانات في المؤسسات
7	استخراج البيانات من الويب ودور بيانات المنتديات في دعم تطبيقات الذكاء الاصطناعي
8	مثال تطبيقي كامل لاستخراج بيانات مدن من صفحة ويب وتخزينها بصيغة JSON
10	استخدام واجهات برمجة التطبيقات للحصول على بيانات الرموز البريدية بصيغة JSON
14	دور بيانات وسائل التواصل الاجتماعي ونقاط البيع في تغذية أنظمة الذكاء الاصطناعي
15	أنظمة التجارة الإلكترونية وإنترنت الأشياء كمصادر رئيسية لبيانات الذكاء الاصطناعي
16	المساعدون الأذكاء وأجهزة إنترنت الأشياء المنزلية والصحية والمرورية كمصادر بيانات
29	المقارنة بين البيانات النوعية والبيانات الكمية في مشاريع الذكاء الاصطناعي
34	أنشطة معالجة البيانات واستخدامها في حلول الذكاء الاصطناعي
36	جمع بيانات مشاريع الذكاء الاصطناعي وتجهيزها واختيار المصادر المناسبة
38	ما هو التحيز في البيانات وأنواعه وتأثيره على مشاريع الذكاء الاصطناعي
46	تحديد مصادر البيانات المناسبة والموثوقة لمشروعات الذكاء الاصطناعي
50	مثال تطبيقي على تنظيف سلسلة زمنية ومعالجة القيم المفقودة
51	اختيار واستخدام هياكل وتنسيقات البيانات المناسبة في مشاريع الذكاء الاصطناعي
54	المزايا والعيوب والاستخدامات الشائعة لتنسيقات CSV و JSON و XML في مشاريع الذكاء الاصطناعي
57	حماية بيانات أنظمة الذكاء الاصطناعي وإعداد مجموعات التدريب والتحقق والاختبار

المقدمة

يمثل هذا الجزء من وحدة «مدخل إلى الذكاء الاصطناعي وتطبيقاته – هدف التعلم ب » الأساس العملي لفهم العنصر الأهم في أي نظام ذكاء اصطناعي ناجح، وهو البيانات . فالبيانات هي الوقود الذي تتعلم منه النماذج الذكية، وهي التي تحدّد دقة القرارات التي تتخذها هذه الأنظمة وجودة التوقعات التي تقدّمها في التطبيقات المختلفة داخل المؤسسات.

يركّز هذا الهدف على بناء فهم منظم لدور البيانات في مشاريع الذكاء الاصطناعي، بدءًا من التعرف على بيانات الذكاء الاصطناعي (ب)، ولماذا تحتاج المؤسسات إلى أنواع مختلفة من البيانات بدل الاعتماد على نوع واحد فقط. كما يتناول المصادر الشائعة للبيانات في المؤسسات، بما في ذلك الأنظمة الداخلية، ومواقع الويب، ومنتديات النقاش، ووسائل التواصل الاجتماعي، وأنظمة نقاط البيع، ومنصات التجارة الإلكترونية، وأجهزة إنترنت الأشياء في البيئات المنزلية والصحية والمرورية.

وتقدّم هذه المادة عددًا من الأمثلة التطبيقية التي تربط المحتوى النظري بالاستخدام الواقعي، مثل:

استخراج بيانات مدن من صفحة ويب وتخزينها بصيغة JSON، واستخدام واجهات برمجة التطبيقات (APIs) للحصول على بيانات الرموز البريدية، إضافة إلى مثال تطبيقي على تنظيف سلسلة زمنية ومعالجة القيم المفقودة. وتهدف هذه الأنشطة إلى تمكين الطالب من التعامل مع بيانات حقيقية يمكن توظيفها في مشاريع دراسية أو تطبيقات عملية في مجال الذكاء الاصطناعي.


كما تتناول المادة المقارنة بين البيانات الكمية والبيانات النوعية، وأنشطة معالجة البيانات وتجهيزها لمشروعات الذكاء الاصطناعي، مع التركيز على اختيار المصادر المناسبة والموثوقة للبيانات، وفهم التحيز في البيانات وأنواعه وتأثيره على مخرجات النماذج الذكية. ويتم كذلك استعراض هياكل وتنسيقات البيانات الأكثر استخدامًا في هذا المجال، مثل CSV و JSON و XML، وبيان مزايا وعيوب واستخدامات كل منها.

وأخيرًا، تؤكد المادة على أهمية حماية بيانات أنظمة الذكاء الاصطناعي، وإعداد مجموعات التدريب والتحقق والاختبار بشكل سليم، بما يضمن بناء نماذج أكثر دقة وعدالة واعتمادية. وبذلك يُصبح الطالب قادرًا على فهم دورة حياة البيانات في مشاريع الذكاء الاصطناعي منذ لحظة جمعها وحتى توظيفها في أنظمة عملية تخدم احتياجات المؤسسات على أرض الواقع.

المخرجات :

1. فهم دور البيانات كوقود رئيسي لأنظمة الذكاء الاصطناعي، وربط ذلك بأمثلة واضحة من الواقع مثل منصّات الفيديو، المتاجر الإلكترونية، ووسائل التواصل الاجتماعي.
2. تحديد وجمع بيانات من مصادر مختلفة (مواقع ويب، منتديات، وسائل تواصل اجتماعي، أنظمة مؤسسية) واختيار ما يناسب فكرة مشروع ذكاء اصطناعي بسيط يمكن تطبيقه فعليًا.
3. تنظيم وتنظيف وتجهيز البيانات للاستخدام العملي من خلال اختيار تنسيقات مناسبة مثل CSV و JSON، ومعالجة المشكلات الشائعة في البيانات مثل القيم المفقودة.
4. التعامل الواعي والمسؤول مع البيانات عبر فهم التحيز في البيانات، وأساسيات حماية بيانات الذكاء الاصطناعي، وتقسيمها إلى مجموعات تدريب وتحقق واختبار، بما يمكّنه من التخطيط لمشروع حقيقي في مجال الذكاء الاصطناعي.

مدخل إلى الذكاء الاصطناعي وتطبيقاته



يستكشف هذا الموضوع تخطيط أحد حلول الذكاء الاصطناعي. ويتناول كيفية التعرف على البيانات
اللزمة

لدعم الحل وكيفية جمعها وإعدادها.

1- بيانات الذكاء الاصطناعي


بيانات الذكاء الاصطناعي هي كل المعلومات الرقمية التي يتعلم منها النظام الذكي مثل النصوص والصور
والاصوات وسجلات التعاملات وبفضل هذه البيانات يكتشف النموذج الانماط ويتعلم مثلا تمييز الوجوه
في الصور او اقتراح فيديو مناسب في منصات البث او كشف عملية احتيال بنكي وكلما كانت البيانات
اوسع واكثر دقة وتنظيما زادت قدرة الذكاء الاصطناعي على التنبؤ واتخاذ قرارات صحيحة .

1.1- أنواع مختلفة من البيانات

عند دراسة هدف التعلم ب يكون المطلوب فهم ان الذكاء الاصطناعي لا يعمل على نوع واحد من
البيانات بل يعتمد على عدة انواع مختلفة تستعمل في مواقف وتطبيقات متنوعة في الحياة العملية وفيما
يلي شرح لاهم هذه الانواع مع امثلة قريبة من واقعنا


1.1.1 البيانات المهيكلة

وهي البيانات التي تكون منظمة في جداول وصفوف واعمدة مثل جداول الرواتب في شركة او سجلات الطلاب في مدرسة حيث يكون لكل عمود معنى محدد مثل الاسم او الرقم الوطني او المعدل ولكل صف سجل واحد لنفس الشخص او العميل هذا النوع من البيانات يسهل تخزينه في قواعد البيانات واستعماله في الخوارزميات التي تحتاج الى ارقام واضحة ومنظمة مثل نماذج التنبؤ بالمبيعات لشركة اتصالات في الاردن



1.1.2 البيانات شبه المهيكلة

هي بيانات بين المهيكلة وغير المهيكلة لا تكون في شكل جدول ثابت لكنها تحتوي على تنظيم داخلي يمكن فهمه مثل ملفات بصيغة JSON او XML او رسائل البريد الالكتروني التي فيها حقول مثل المرسل والموضوع والنص هذه البيانات تحتاج اولا الى بعض المعالجة لاستخراج الحقول المهمة قبل استخدامها في نماذج الذكاء الاصطناعي مثلا عند تحليل رسائل دعم العملاء في شركة لخدمات الانترنت لتحديد اكثر المشاكل شيوعا



1.1.3-البيانات غير المهيكلة

هي البيانات التي لا تتبع **قالباً ثابتاً** مثل النص الحر والصور والفيديو والملفات الصوتية ومنشورات شبكات التواصل الاجتماعي أغلب المحتوى الذي يتعامل معه الانسان يومياً يقع في هذه الفئة انظمة مثل ChatGPT تتعامل مع نصوص غير مهيكلة كما ان انظمة التعرف على الوجوه تتعامل مع صور غير مهيكلة تحتاج هذه البيانات الى تقنيات خاصة للمعالجة مثل رؤيا الحاسوب او معالجة اللغة الطبيعية

1.1.4-البيانات الرقمية العديدة


وهي بيانات تمثل **اعداداً** يمكن جمعها وطرحها وحساب المتوسط لها مثل درجات الحرارة في عمان خلال شهر او اسعار الوقود يومياً او عدد الزوار لموقع الكتروني تستخدم هذه البيانات بكثرة في النماذج التي **تتنبأ باتجاهات** الاسعار او الحمولة المتوقعة على شبكة الكهرباء او الطلب على منتج معين في السوق

1.1.5-البيانات الفئوية الوصفية

هي بيانات تصف **فئات او اصنافاً** بدلا من اعداد مثل نوع السيارة بنزين او كهرباء او هجين او نوع الاشتراك انترنت منزلي او فايبر او موبايل او محافظة السكن عمان اربد الزرقاء لا يمكن جمع هذه القيم حسابيا لكنها مفيدة جدا لتقسيم العملاء وتحليل سلوك كل فئة في الانظمة الذكية

البيانات الغثوية (الوصفية): تصنيف لا يقبل الجمع الحسابي

لا معنى رياضي = بنزين + كهرباء لا معنى رياضي



1.1.6-البيانات النصية

وهي كل ما يكتب **بلغة البشر** مثل المقالات والتقارير ورسائل الواتساب والتغريدات وتعليقات المستخدمين على التطبيقات تعتمد عليها **أنظمة فهم اللغة** مثل محركات البحث والمساعدات الرقمية وبرامج تحليل آراء الناس عن منتج ما مثلاً يمكن لنظام ذكاء اصطناعي أن يحلل تعليقات الزبائن عن مطعم في إربد ليعرف هل الرأي العام إيجابي أم سلبي وما هي أكثر الشكاوى تكراراً

1.1.7-بيانات الصور والفيديو

تتضمن **الصور الثابتة** ومقاطع الفيديو مثل صور الكاميرات الأمنية وصور الأشعة الطبية وصور المنتجات في المتاجر الإلكترونية تستخدم هذه البيانات في تطبيقات كثيرة مثل نظام يراقب حركة المرور في مدينة عمان أو نظام يساعد الأطباء على اكتشاف **علامات مبكرة لمرض** معين من صورة الأشعة

1.1.8-البيانات الصوتية

وهي تسجيلات **الكلام أو الأصوات** مثل المكالمات الهاتفية ورسائل الصوت في التطبيقات وأصوات المكنات في المصانع تستخدم في أنظمة التعرف على الكلام للتحويل **من صوت إلى نص** وفي مراقبة حالة الآلات عن طريق سماع تغيرات غير طبيعية في صوتها كما تستخدم في المساعدات الصوتية التي تفهم أوامر المستخدم بالعربية أو الانجليزية

1.1.9-بيانات الحساسات وانترنت الاشياء

هي البيانات التي **تجمعها اجهزة الاستشعار** مثل حساسات الحرارة والرطوبة وحساسات الحركة والضغط وعدادات الكهرباء الذكية في المنازل هذه البيانات غالبا تكون متدفقة بشكل مستمر وتستخدم في أنظمة المراقبة والتحكم مثل نظام ذكي يدير استهلاك الطاقة في مبنى حكومي او نظام ري ذكي في مزرعة في الاردن يعتمد على رطوبة التربة وحالة الطقس

1.1.10-البيانات المكانية الزمنية

هي بيانات تحتوي على **مكان وزمان معا** مثل نقاط تحديد المواقع GPS لمسار حافلة او بيانات توضح حركة سيارات الشحن خلال اليوم او موقع الهاتف مع الوقت هذا النوع مهم **في تطبيقات الخرائط وخدمات التوصيل** وتحليل الازدحام المروري والتخطيط لشبكات النقل العام

هذه الانواع المختلفة من البيانات تشكل **الوقود الحقيقي** لأنظمة الذكاء الاصطناعي فكلما كانت البيانات متنوعة وجودتها عالية كان من الممكن بناء نماذج ادق وافضل اداء في مساعدة الافراد والمؤسسات على اتخاذ قرارات افضل.

فيديوهات شرح :

<https://www.youtube.com/watch?v=c0vWSmaO1eg>

<https://www.youtube.com/watch?v=JUzSjkmJpOo>

<https://www.youtube.com/watch?v=OVDktxMJB8Y>

منصة أساس التعليمية

1.2- لماذا تستخدم المؤسسات انواعا مختلفة من البيانات



1.2.1- اختلاف شكل توفر البيانات في الواقع

في الحياة العملية كثيرا ما تفرض البيئة شكل البيانات على المؤسسة فلا تستطيع الشركة ان تقول اريد البيانات مهيكلة دائما بل **تضطر للتعامل مع الشكل المتاح** فمثلا شركات الاعلام والتسويق الرقمي تعتمد على ما ينشره الناس في شبكات التواصل من تعليقات وصور ومقاطع فيديو ورسائل قصيرة وكل ذلك بيانات غير مهيكلة لا تأتي في جداول منظمة وكذلك تطبيقات التوصيل وتطبيقات حجز السيارات تولد سجلات لمسارات الحركة وازمنة الوصول ومواقع السائقين على الخارطة وهي بيانات مكانية وزمنية وشبه مهيكلة لذلك تلجأ المؤسسة الى بناء ادوات قادرة على استقبال هذه الانواع كما **هي وتحويلها الى معلومات قابلة للتحليل** بدلا من محاولة اجبار المستخدمين على تعبئة جداول صلبة لا تناسب طبيعة استخدامهم

منصة أساس التعليمية

1.2.2- الحاجة الى وصول سريع ومنظم الى بيانات حساسة

بعض مجالات العمل **لا تحتمل الفوضى** في البيانات مثل الحسابات والرواتب وسجلات المخزون وسجلات الموظفين او المرضى فهذه المعلومات تستخدم في تقارير رسمية وقرارات مالية وقانونية ولذلك تصر المؤسسة على ان تدخل هذه البيانات في شكل جداول مهيكلة يمكن البحث فيها خلال ثوان قليلة فالمحاسب يحتاج ان يستخرج تقريراً عن مصروفات الشهر وقسم الموارد البشرية يحتاج ان يعرف رصيد اجازات موظف معين وقسم المستودعات يحتاج ان يعرف الكميات المتبقية من كل صنف وهذه العمليات لا تنجح بكفاءة **الا اذا كانت البيانات مهيكلة ومتراصة** ويمكن ربطها بسهولة مع انظمة اخرى مثل نظام الرواتب او نظام الفوترة او نظام شؤون الموظفين

1.2.3- الاستفادة من قوة الذكاء الاصطناعي مع البيانات غير المهيكلة

مع تطور خوارزميات معالجة اللغة الطبيعية ورؤيا الحاسوب وتحليل الصوت أصبحت البيانات غير المهيكلة **كنزا** حقيقيا للمؤسسات فالمستشفيات على سبيل المثال تخزن صور الأشعة وتحاليل المختبر على شكل ملفات صور وملفات تقارير مطولة وباستخدام الذكاء الاصطناعي يمكن تدريب نماذج تتعلم من الصورة نفسها لاكتشاف علامات مبكرة للمرض تكون أحيانا أدق من الوصف المختصر الذي يكتبه الطبيب في قاعدة البيانات المهيكلة وكذلك مراكز خدمة العملاء التي تسجل المكالمات يمكنها تحويل الصوت الى نص ثم تحليل النصوص لاكتشاف أكثر المشاكل تكرارا ودرجة رضا الزبائن او غضبهم وهذا النوع من الفهم العميق لا يمكن الوصول اليه من خلال عدد محدود من الخانات في جدول مثل نوع المشكلة وتاريخها فقط


1.2.4- تطور البنية التقنية الى تطبيقات وخدمات مصغرة

الكثير من المؤسسات انتقل من **تطبيق ضخمة واحد الى مجموعة من الخدمات المصغرة** التي يتواصل بعضها مع بعض عبر واجهات برمجة تطبيقات وغالبا ما تتبادل هذه الخدمات بيانات بصيغ مثل جيسون وهي بيانات شبه مهيكلة وليست جداول صافية كما تولد هذه الخدمات سجلات احداث كثيرة توثق كل ما يحدث داخل النظام وهذه السجلات تكون نصية وغير مهيكلة لكنها مفيدة جدا في مراقبة الاداء والكشف المبكر عن الاعطال وسلوكيات الاستخدام غير الطبيعية لذلك تجد المؤسسة نفسها تملك مزيجا من الجداول المهيكلة المتعلقة بالمعاملات الرسمية ومجموعة ضخمة من الملفات والرسائل شبه المهيكلة وغير المهيكلة الخارجة من تواصل هذه الخدمات فيما بينها

1.2.5- اهمية بيانات السلاسل الزمنية في التنبؤ

هناك نوع خاص من البيانات تعتمد عليه المؤسسات في **التنبؤ** يسمى بيانات **السلاسل الزمنية** وهو مجموعة من القياسات المتكررة مع الزمن مثل قراءة عداد الكهرباء كل ساعة او تسجيل عدد السيارات المارة كل خمس دقائق او سعر سهم معين كل يوم وهذا النوع ضروري لجهات مثل خبراء الارصاد الذين يتنبؤون بالطقس ووسطاء البورصة الذين يحاولون توقع حركة الاسهم ومهندسي البنية التحتية الذين يراقبون حركة المرور في المدن والذكاء الاصطناعي هنا يستفيد من **ترتيب القيم مع الزمن** ليكتشف الاتجاهات الموسمية والقمم والانخفاضات ويقترح قرارات مثل زيادة قدرة شبكة الكهرباء في فترات معينة او تغيير توقيت الاشارات الضوئية في تقاطعات محددة او تعديل سياسة التخزين في مستودع بناء على الطلب المتوقع

لماذا تتعامل المؤسسات مع أشكال متنوعة من البيانات؟



1.3-المصادر الشائعة للبيانات في المؤسسات



1.3.1-نظم المعاملات الداخلية

كل مؤسسة تقريباً تمتلك أنظمة معلومات تشغل العمل اليومي مثل نظام المبيعات ونظام المخزون ونظام شؤون الموظفين ونظام شؤون الطلبة ونظام السجلات الطبية وكل عملية بيع أو شراء أو تسجيل حضور أو صرف راتب أو ادخال فحص طبي **تنتج سجلاً جديداً مهيكلاً في قاعدة البيانات** وهذه الأنظمة هي العمود الفقري للبيانات المهيكلة التي تبني عليها التقارير المالية والإدارية وتستخدم لاحقاً لتدريب نماذج ذكاء اصطناعي تتنبأ بالمبيعات أو المصاريف أو حاجات التوظيف أو احتمالية تسرب الطلاب

1.3.2-الأجهزة والحساسات وانترنت الأشياء

مع انتشار العدادات الذكية والحساسات في المزارع والمصانع والمباني أصبحت قراءة البيئة المحيطة تتم أوتوماتيكياً فهناك حساسات لحرارة الهواء ورطوبة التربة وضغط السوائل وشدة الإضاءة وجود

الحركة وتركيز الغازات الملوثة وهذه الاجهزة ترسل بيانات رقمية متتابعة زمنيا الى خوادم المؤسسة فتتشكل لدينا سلاسل زمنية يمكن استخدامها في أنظمة ري ذكية لا تعمل الا عند الحاجة وفي أنظمة ادارة طاقة تقلل استهلاك الكهرباء وفي أنظمة مراقبة حالة الآلات التي تنبه عند **ظهور نمط** يدل على بداية عطل قبل ان تتوقف الماكينة بشكل كامل

1.3.3-تفاعل المستخدمين مع التطبيقات والمواقع

كل حركة يقوم بها المستخدم داخل تطبيق موبايل او موقع الكتروني يمكن تسجيلها مثل الصفحات التي يزورها والوقت الذي يقضيه في كل صفحة والازرار التي يضغطها ونوع الجهاز الذي يستخدمه ونظام التشغيل وهذه تسمى بيانات الاستخدام او بيانات التتبع وهي غالبا شبه مهيكلة او غير مهيكلة لكنها تعطي صورة غنية عن سلوك المستخدمين وبالأستفادة من الذكاء الاصطناعي يمكن **تحليل هذه البيانات** لتحسين تصميم الواجهات وتقليل الخطوات التي ترهق المستخدم وبناء **نظم توصية** تقترح عليه منتجات او دورات تدريبية او مقالات تتناسب مع اهتماماته وتاريخ تصفحه

1.3.4-المستندات والارشيفات الداخلية

الى جانب قواعد البيانات التقليدية تنتج المؤسسات كما كبيرا **من الوثائق** مثل التقارير الدورية ومحاضر الاجتماعات والعقود والمراسلات الرسمية والعروض التقديمية وهذه المواد تكون في الغالب ملفات نصية او نصية ممزوجة بجداول وصور وتعد مصدرا مهما للمعرفة المخفية داخل المؤسسة ومع تقنيات الذكاء الاصطناعي يمكن فحص هذا الارشيف للبحث الذكي عن المستندات ذات الصلة بموضوع ما وتلخيص التقارير الطويلة الى نقاط رئيسية واستخراج البنود المتشابهة من العقود لمساعدة الادارة القانونية على مقارنة الصياغات المختلفة

1.3.5-البيانات المفتوحة والجهات الحكومية


بعض الوزارات والهيئات في دول عديدة تنشر مجموعات بيانات **مفتوحة للجمهور** مثل بيانات التعداد السكاني والتعليم والصحة والطرق والاقتصاد وغالبا ما تكون هذه **البيانات مهيكلة** او شبه مهيكلة **ومجانية** الاستخدام ويمكن للشركات ان تدمجها مع بياناتها الداخلية للحصول على تحليل اعمق فمثلا يمكن لمتجر تجزئة ان يربط بين مبيعاته السنوية في مدينة معينة وبين بيانات عدد السكان ومتوسط الدخل في نفس المدينة ليفسر ارتفاع او انخفاض المبيعات ويقرر ما اذا كان بحاجة الى تعديل اسعاره او حملاته التسويقية او حتى موقع فرعه

1.3.6-الويب ومواقع التواصل

يعد الويب اليوم واحدا من **اخصم مصادر البيانات** المتاحة حيث يمكن استخراج بيانات من مواقع الاخبار والمتاجر الالكترونية والمدونات وصفحات الشركات والحسابات العامة في شبكات التواصل الاجتماعي باستخدام تقنيات مثل مسح الويب التي تعتمد على برامج تزور الصفحات وتلتقط اجزاء معينة من النص او الاسعار او التقييمات وتحولها الى بيانات قابلة للتحليل وتستخدم المؤسسات هذه البيانات في مجالات مثل بحوث السوق لمقارنة اسعار المنافسين ومراقبة العروض ومتابعة تقييمات

المنتجات وتحليل صورة العلامة التجارية لدى الجمهور وجمع بيانات تدريب لنماذج تعلم آلي تحتاج الى كمية كبيرة من النصوص او الصور او التوصيفات

المصادر الشائعة للبيانات في المؤسسات




فيديوهات شرح :

https://www.youtube.com/watch?v=xGu_OPxAu90

<https://www.youtube.com/watch?v=ZX0Jsm9BB-Y>

<https://www.youtube.com/watch?v=irDEWxDQAFg>

منصة أساس التعليمية



الفقرة الثالثة عند التفكير في استخراج البيانات من الويب يجب ان تكون **السلامة القانونية والاخلاقية** حاضرة دائما لان بعض المواقع تعتبر جمع البيانات بشكل آلي مخالفة لشروط الاستخدام الخاصة بها لذلك من المهم قراءة سياسة الموقع والتأكد من السماح بالوصول الآلي وعدم تجاوز الحدود المنصوص عليها في عدد الطلبات كما يجب احترام ملفات الضبط مثل **robots txt** التي تحدد الاجزاء المسموح للبرامج بزيارتها الى جانب ذلك ينبغي تجنب جمع بيانات شخصية حساسة او تخزينها دون حاجة حقيقية او دون الحصول على موافقة صريحة من اصحابها لان الهدف من استخراج البيانات هو التحليل وتحسين الخدمات وليس انتهاك الخصوصية او الاضرار بالمواقع

الفقرة الرابعة تعد **المنتديات ولوحات** النقاش على الانترنت مصدرا غنيا جدا للبيانات لانها تعتمد على المحتوى الذي ينشئه المستخدمون بأنفسهم **وتظل محدثة بشكل مستمر** فهناك عناوين للمواضيع الرئيسية ومشاركات وردود تمثل آراء وتجارب حقيقية وملفات تعريف للمستخدمين قد تتضمن معلومات مثل البلد او المدينة والاهتمامات وهوايات اصحاب الحسابات كما توجد بنية تنظيمية للمنتدى على شكل اقسام متخصصة وموضوعات فرعية تعكس طريقة تصنيف النقاشات وتوجد ايضا بيانات مرتبطة بالزمن مثل تاريخ انشاء كل موضوع ووقت كل رد وعدد المشاركات التي يكتبها العضو خلال فترة معينة اضافة الى بيانات وصفية مثل الوسوم المستخدمة لتصنيف المشاركات وعدد المشاهدات وعدد الاعجابات او التصويتات للاعلى والاسفل والروابط المضمنة داخل النصوص التي تشير الى مصادر خارجية كل هذه الطبقات من البيانات تجعل المنتديات بيئة مثالية لجمع مادة خام يمكن تحليلها لفهم سلوك المستخدمين واتجاهات الحوار حول قضية معينة

الفقرة الخامسة بالنسبة للذكاء الاصطناعي تشكل البيانات المستخرجة من الويب عموما ومن المنتديات وصفحات التواصل خصوصا مادة **تدريبية ثمينة فالنصوص القصيرة والطويلة** تساعد في تدريب نماذج فهم اللغة وتحليل المشاعر والتعليقات حول منتج او خدمة والصور المضمنة يمكن ان تستخدم في تدريب نماذج رؤيا حاسوب للتعرف على انواع المنتجات او الشعارات والبيانات الزمنية تساعد على فهم كيف يتغير الاهتمام بموضوع معين عبر الايام والاسباب ومع ذلك تبقى مسؤولية المؤسسة ان تقوم بتنظيف هذه البيانات وحذف ما يكشف عن هوية الاشخاص بشكل مباشر قبل استخدامها في التحليل او في نماذج الذكاء الاصطناعي حتى تحقق الفائدة من هذه البيانات دون الاضرار بحقوق وخصوصية مستخدمي الويب

1.4.1- مثال تطبيقي كامل لاستخراج بيانات مدن من صفحة ويب وتخزينها بصيغة JSON

1.4.2 مثال على مقطع HTML لمدينة واحدة

```
<div class="city-card">
  <h2 class="city-name">
    <span class="city-label">City:</span>
    Amman
  </h2>

  <div class="city-info">
    <strong>Country:</strong>
    <span class="city-country">Jordan</span><br/>

    <strong>Temperature (°C):</strong>
    <span class="city-temp">23</span><br/>

    <strong>Humidity (%):</strong>
    <span class="city-humidity">44</span><br/>
  </div>
</div>
```

نفترض ان هناك صفحة ويب تعرض معلومات عن عدة مدن في العالم مثل اسم المدينة والدولة ودرجة الحرارة الحالية ونسبة الرطوبة ويتم تنظيم كل مدينة داخل صندوق HTML واحد كما في المقطع التالي لمدينة واحدة فقط

في هذا المقطع نلاحظ ما يلي

فقرة واحدة تحتوي على معلومات مدينة كاملة داخل وسم **div** يحمل الصنف city card
اسم المدينة مكتوب داخل **h2** وله الصنف city name
اسم الدولة محفوظ داخل **span** له الصنف city country
درجة الحرارة داخل **span** له الصنف city temp
نسبة الرطوبة داخل **span** له الصنف city humidity

هذا التنظيم يجعل البيانات من وجهة نظر المستخدم غير مهيكلة لأنها جزء من تصميم صفحة لكن من وجهة نظر المبرمج هي بيانات شبه مهيكلة يمكن الوصول إليها عن طريق اصناف HTML

1.4.3- كود بايثون لاستخراج بيانات جميع المدن من الصفحة

الان سيتم استخدام بايثون مع مكتبة **requests** لجلب الصفحة من الويب ومكتبة **BeautifulSoup** لتحليل **HTML** ثم تخزين البيانات في ملف JSON منظم

هذا المثال يوضح سلسلة من الخطوات العملية

```
1 import requests
2 from bs4 import BeautifulSoup
3 import json
4
5 url = "https://example.com/weather/cities"
6 headers = {
7     "User-Agent": "Mozilla/5.0 (compatible; StudentBot/1.0)"
8 }
9
10 response = requests.get(url, headers=headers)
11
12 if response.status_code != 200:
13     raise Exception(f"فشل في جلب الصفحة، رمز الحالة: {response.status_code}")
14
15 soup = BeautifulSoup(response.text, "html.parser")
16
17 cities_data = {}
18
19 for city_div in soup.find_all("div", class_="city-card"):
20     name_tag = city_div.find("h2", class_="city-name")
21     city_name = name_tag.get_text(strip=True).replace("City:", "").strip()
22
23     country_tag = city_div.find("span", class_="city-country")
24     country = country_tag.get_text(strip=True) if country_tag else ""
25
26     temp_tag = city_div.find("span", class_="city-temp")
27     temperature = temp_tag.get_text(strip=True) if temp_tag else ""
28
29     humidity_tag = city_div.find("span", class_="city-humidity")
30     humidity = humidity_tag.get_text(strip=True) if humidity_tag else ""
31
32     cities_data[city_name] = {
33         "country": country,
34         "temperature_c": temperature,
35         "humidity_percent": humidity
36     }
37
38 with open("cities_weather.json", "w", encoding="utf-8") as json_file:
39     json.dump(cities_data, json_file, ensure_ascii=False, indent=4)
```

ارسال طلب برمجي الى صفحة الويب مع تمرير **ترويسة** تحتوي على سلسلة وكيل مستخدم **User Agent** حتى يبدو الطلب اقرب الى طلب متصفح حقيقي التأكد من نجاح الطلب قبل المتابعة حتى لا يحاول البرنامج تحليل صفحة فارغة او رسالة خطأ

تحليل كود HTML والبحث عن جميع العناصر div ذات الصنف city card التي تمثل كل منها مدينة

استخراج النصوص من العناصر الداخلية

h2 و span وتنظيفها من الكلمات الزائدة مثل City

بناء قاموس في بايثون حيث يكون اسم المدينة هو المفتاح وتحت كل مفتاح توجد معلومات الدولة والحرارة والرطوبة

تحويل هذا القاموس الى ملف **JSON** منظم يمكن استخدامه لاحقا في تطبيقات ذكاء اصطناعي او في تحليلات اخرى

1.4.4 مثال على جزء من ملف JSON الناتج

بعد تنفيذ الكود السابق قد يبدو جزء من ملف **cities_weather json** كما يلي

```
{
  "Amman": {
    "country": "Jordan",
    "temperature_c": "23",
    "humidity_percent": "44"
  },
  "Cairo": {
    "country": "Egypt",
    "temperature_c": "28",
    "humidity_percent": "52"
  },
  "Riyadh": {
    "country": "Saudi Arabia",
    "temperature_c": "30",
    "humidity_percent": "38"
  }
}
```

يمكن ملاحظة ان البيانات اصبحت الان منظمة في صورة ازواج مفتاح وقيمة خالية من وسوم HTML وغير مرتبطة بتصميم الصفحة جاهزة للدخول مباشرة في نموذج تعلم آلي يتنبأ مثلا بدرجة الحرارة او نسبة الرطوبة في مدينة معينة بناء على بيانات اخرى مثل الوقت من السنة او الارتفاع عن سطح البحر

1.4.5-ملاحظة حول الطلبات البرمجية وواجهات برمجة التطبيقات


عند استخدام طلبات برمجية للوصول الى بيانات الويب من المهم احترام سياسات المواقع وعدم ارسال عدد كبير من الطلبات في وقت قصير والالتزام بما تسمح به شروط الاستخدام بعض المواقع قد ترفض الطلبات التي يكون فيها وكيل المستخدم واضحا انه برنامج وليس متصفحات معروفة وفي المقابل تقدم مواقع اخرى واجهات برمجة تطبيقات عامة API تسمح بالحصول على البيانات نفسها بصيغة منظمة مثل JSON دون الحاجة الى تحليل HTML وغالبا تحتاج هذه الواجهات الى مفتاح API يحصل عليه المطور بعد التسجيل وتحدد له حدا اقصى لعدد الطلبات المسموح بها في اليوم.

استخدام واجهات برمجة التطبيقات للحصول على بيانات الرموز البريدية بصيغة JSON

في هذا المثال سيتم توضيح فكرة استخدام واجهة **برمجة تطبيقات** عامة للحصول على معلومات جغرافية مرتبطة بالرموز البريدية وكيفية ارسال طلب برمجي بسيط واستقبال استجابة بصيغة JSON يمكن لاحقا توظيفها في تطبيقات الذكاء الاصطناعي

تخيل خدمة ويب اسمها خدمة الرموز البريدية الجغرافية تقدم قاعدة بيانات مفتوحة عن الرموز البريدية في دولة معينة مثل المملكة المتحدة او اي دولة اخرى وتتيح للمطورين الاستعلام عن موقع الرمز البريدي وخطوط العرض والطول والمنطقة الادارية المرتبطة به عن طريق واجهة برمجة تطبيقات مفتوحة متاحة عبر بروتوكول **HTTP** هذا النوع من الواجهات يشبه الجسر الذي يربط تطبيقك بقاعدة بيانات خارجية بحيث ترسل اليه رمزا بريديا وتستقبل في المقابل بيانات منظمة بصيغة **JSON** بدلا من صفحة HTML عادية يمكن قراءة هذه البيانات آليا واستخدامها في تطبيقات مختلفة مثل عرض موقع العنوان على خريطة او حساب اقرب فرع لخدمة توصيل معينة الى هذا العنوان

postcodes.io+1



واجهة الخدمة تعرّف نقطة نهاية رئيسية للاستعلام عن رمز بريدي واحد على سبيل المثال يمكن ان يكون العنوان بالشكل التالي

<https://api/postcodesio/postcodes> رمز بريدي

عندما يرسل التطبيق طلب **GET** الى هذا العنوان مع تعويض رمز بريدي فعلي مثل **SW1A 1AA** يحصل على استجابة في صورة نص JSON هذه الاستجابة تحتوي على مجموعة ازواج مفتاح وقيمة مثل الرمز البريدي والبلد وخط العرض وخط الطول والمنطقة الادارية وغيرها ما يهم الطالب هنا ان هذه البيانات اصبحت منظمة وجاهزة مباشرة للاستخدام داخل البرنامج **ولا تحتاج الى تنظيف HTML** او البحث اليدوي داخل كود الصفحة

جزء مبسط من استجابة JSON يمكن ان يبدو مثلاً هكذا

```
{
  "status": 200,
  "result": {
    "postcode": "SW1A 1AA",
    "country": "England",
    "region": "London",
    "latitude": 51.5010,
    "longitude": -0.1415
  }
}
```

قيمة في الحقل status تشير الى نجاح الطلب اما الكائن الموجود داخل result فيحمل البيانات الجغرافية الحقيقية التي يهتم بها التطبيق مثل موقع الرمز البريدي على الخريطة هذا الشكل من البيانات مناسب جداً لتغذية نماذج ذكاء اصطناعي تحاول مثلاً تقدير زمن التوصيل المتوقع لكل منطقة او تحليل توزيع الطلبات حسب الاحياء والمناطق

للوصول الى هذه البيانات لا يشترط دائماً استخدام متصفح الويب يمكن كتابة برنامج صغير بلغة بايثون يرسل طلب GET ويقرأ الاستجابة مثال مبسط على ذلك

```
import requests

base_url = "https://api.postcodes.io/postcodes"
postcode_value = "SW1A 1AA"

response = requests.get(f"{base_url}/{postcode_value}")

if response.status_code == 200:
    payload = response.json()
    info = payload["result"]
    print("الرمز البريدي:", info["postcode"])
    print("البلد:", info["country"])
    print("المنطقة:", info["region"])
    print("خط العرض:", info["latitude"])
    print("خط الطول:", info["longitude"])
else:
    print("حدثت مشكلة في الطلب ورمز الحالة هو:", response.status_code)
```


الكود السابق ينفذ الخطوات الاتية جلب محتوى عنوان واجهة البرمجة بصيغة JSON ثم تحويل النص الى كائن بايثون باستخدام الدالة json ثم الوصول الى الحقل result واستخراج القيم المهمة وطباعتها ويمكن بدلا من الطباعة تخزين هذه القيم في قاعدة بيانات او تمريرها الى جزء اخر من النظام مثل نموذج تعلم آلي او خدمة ترسم خريطة تفاعلية

هذا النوع من الطلبات يسمى **طلبا برمجيا** لان الذي يرسله ليس المستخدم يدويا من المتصفح بل برنامج او نص برمجي وغالبا ما يتضمن الطلب ترويسة تسمى سلسلة وكيل المستخدم **User Agent** تخبر الخادم بنوع البرنامج الذي ارسل الطلب مثل متصفح معين او مكتبة بايثون بعض المواقع ترفض الطلبات التي تأتي من سكربتات برمجية اذا لم يكن استخدامها منصوصا عليه في شروط الخدمة ولهذا يجب دائما قراءة سياسة الموقع قبل بناء برنامج يرسل اليه عددا كبيرا من الطلبات او يستخدم بياناته في خدمات تجارية

في المقابل كثير من المواقع وخصوصا التي تعتمد على بيانات مفتوحة توفر واجهة برمجة تطبيقات رسمية وتوثيقا كاملا يشرح نقاط النهاية المتاحة والمعاملات التي يمكن تمريرها وصيغ الاستجابة واحيانا تحدد حدودا لعدد الطلبات في اليوم وتستخدم مفاتيح API للتحكم في من يحق له الوصول الى البيانات وفي حدود الاستخدام المسموح به توجد امثلة حقيقية على ذلك في خدمات الطقس المفتوحة التي تقدم بيانات حالة الطقس الحالية والتوقعات عبر واجهة JSON للمطورين وكذلك في منصات البيانات الحكومية المفتوحة في الاردن التي تتيح مجموعات بيانات قابلة للقراءة بالالة يمكن استدعاؤها من خلال تطبيقات ويب او موبايل

بهذه الطريقة يرى الطالب كيف يمكن ربط تطبيق بسيط بواجهة برمجة تطبيقات عامة للحصول على بيانات جغرافية نظيفة بصيغة JSON ثم استغلالها في حلول ذكاء اصطناعي مثل تحليل التوزيع المكاني للزبائن او اختيار اقرب نقطة خدمة لكل عنوان بريدي او دمج هذه البيانات مع مصادر بيانات اخرى مثل بيانات التعداد السكاني والمرور من بوابات البيانات المفتوحة لبناء نماذج تنبؤية اكثر دقة وسلامة في القرار

استخدام واجهات برمجة التطبيقات للحصول على بيانات الرموز البريدية بصيغة JSON




1.5- استخدام بايثون لإرسال طلبات برمجية إلى واجهة الرموز البريدية والتعامل مع استجابات JSON وأكواد الحالة

في هذا الجزء سنرى مثالا عمليا كاملا لكيفية ارسال طلب برمجي الى واجهة تطبيقات للرموز البريدية باستخدام بايثون مع التعامل مع ترويسة وكيل المستخدم وفحص رمز حالة HTTP ثم قراءة البيانات بصيغة JSON والتعامل مع حالة الخطأ عندما يكون الرمز البريدي غير صحيح

1.5.1- فكرة الطلب البرمجي وفائدة وكيل المستخدم

عندما يكتب المستخدم عنوان واجهة برمجة التطبيقات في شريط العنوان في المتصفح ويرسل الطلب يذهب طلب HTTP GET الى **الخادم** ثم يعيد الخادم استجابة غالبا على شكل **JSON** نفس الشيء يمكن فعله من داخل برنامج بايثون بدلا من المتصفح تماما لكن بعض **الخواص ترفض الطلبات القادمة من برامج مجهولة** وتسمح فقط بما يشبه المتصفحات الفعلية لذلك نضيف في الطلب ترويسة تسمى **وكيل المستخدم User Agent** نكتب فيها قيمة قريبة من المتصفحات الشائعة او قيمة واضحة تعرّف برنامجنا بشكل محترم وبذلك يكون الطلب البرمجي مشابها لما يرسله المتصفح وتكون الاستجابة هي نفسها التي نراها لو فتحنا العنوان في المتصفح يدو



يا

1.5.2- مثال على كود بايثون يرسل طلب GET ويتحقق من النجاح

```
import requests
from urllib.parse import quote

postcode = "SW1A 0AA"

base_url = "https://api.postcodes.io/postcodes"
full_url = f"{base_url}/{quote(postcode)}"

headers = {
    "User-Agent": "Mozilla/5.0 (StudentProject/1.0)"
}

try:
    response = requests.get(full_url, headers=headers, timeout=5)

    if response.status_code == 200:
        payload = response.json()
        result = payload["result"]

        print("الرمز البريدي:", result["postcode"])
        print("البلد:", result["country"])
        print("المنطقة:", result["region"])
        print("خط العرض:", result["latitude"])
        print("خط الطول:", result["longitude"])

    elif response.status_code == 404:
        print("الرمز البريدي غير موجود في الخدمة")

    else:
        print("حدث خطأ في الطلب ورمز الحالة هو:", response.status_code)

except requests.exceptions.RequestException as error:
    print("تخطى الاتصال بالخدمة بسبب:", error)
```

هذا الكود يقوم بعدة خطوات في تسلسل واضح يحدد الرمز البريدي ويحوّله إلى صيغة صالحة للعنوان باستخدام quote ثم يبني عنوان واجهة البرمجة الكامل ويضيف ترويسة وكيل المستخدم بعد ذلك يرسل الطلب ويتحقق من رمز الحالة إذا كانت القيمة 200 فهذا يعني أن الطلب ناجح فيحوّل الاستجابة من نص JSON إلى كائن بايثون ويقرأ الحقول المهمة مثل البلد والمنطقة وخطي العرض والطول إذا كانت القيمة 404 فهذا يعني أن الرمز البريدي الذي ادخله المستخدم غير موجود في قاعدة بيانات الخدمة ويتم عرض رسالة مناسبة أما إذا ظهر رمز حالة آخر مثل 500 أو 403 فيتم عرض رسالة عامة توضح وجود مشكلة مختلفة وأخيراً تمت احاطة الطلب بكتلة try...except للتعامل مع أخطاء الاتصال مثل انقطاع الانترنت أو انتهاء المهلة.

1.5.3 شكل البيانات عند نجاح الطلب

```
{
  "status": 200,
  "result": {
    "postcode": "SW1A 0AA",
    "country": "England",
    "region": "London",
    "latitude": 51.4998,
    "longitude": -0.1247
  }
}
```

عندما ينجح الطلب وتكون حالة HTTP تساوي 200 تعيد الخدمة نصاً بصيغة JSON يشبه مثلاً

هذا الشكل من البيانات منظم جداً فهناك حقل عام اسمه status يوضح ان الاستجابة ناجحة ثم كائن داخلي اسمه result يحوي القيم التي تهتم التطبيق مثل الرمز البريدي والبلد والمنطقة وخطي العرض والطول ويمكن بسهولة تخزين هذه البيانات في قاعدة بيانات او استخدامها في رسم نقطة على خريطة او في تدريب نموذج ذكاء اصطناعي يحلل توزيع الطلبات حسب المناطق

1.5.4 التعامل مع حالة الخطأ 404 والاطء الاخرى

اذا كتب المستخدم رمزا بريديا غير صحيح او رمزا لا تعرفه الخدمة ترسل استجابة مختلفة يكون فيها status مساويا 404 مع رسالة خطأ توضح ان الرمز غير موجود وعلى البرنامج ان يتحقق من هذا الرمز قبل محاولة استخدام نتيجة الاستعلام فبدلاً من وقوع خطأ اثناء قراءة الحقول من result يعرض البرنامج رسالة واضحة للمستخدم تفيد بان الرمز المدخل غير صحيح او غير مدعوم وبنفس الفكرة يمكن استخدام رموز حالة اخرى مثل 400 لطلبات غير صحيحة او 401 لعدم وجود صلاحية او 500 لخطأ داخل الخادم المهم للطالب هنا ان يفهم ان فحص response status code خطوة اساسية في اي برنامج يتعامل مع واجهات برمجة تطبيقات لانها تحدد ما اذا كان من الآمن متابعة تحليل البيانات ام يجب معالجة الخطأ اولاً.

فيديوهات شرح : <https://www.youtube.com/watch?v=xSUSR-yAb5w>

<https://www.youtube.com/watch?v=l19IXviVlVl>

https://www.youtube.com/watch?v=taL3r_JpwBg

<https://www.youtube.com/watch?v=hVFD6Mjzsac>

<https://www.youtube.com/playlist?list=PLMTdZ61eBnyqzVhegrlKy38Zwzky-eugX>

1.6 دور بيانات وسائل التواصل الاجتماعي ونقاط البيع في تغذية أنظمة الذكاء الاصطناعي




1.6.1 وسائل التواصل الاجتماعي كمصدر ضخم للبيانات

منصات التواصل الاجتماعي اليوم مثل المنصات العالمية المعروفة تعد من أكبر مصادر البيانات في العالم لان ملايين المستخدمين من مختلف الاعمار يدخلون اليها يوميا من الهواتف الذكية والحواسيب ويشاركون النصوص والصور والفيديو والقصص القصيرة وبهذا لا يقتصر الامر على محتوى المنشور نفسه بل يتولد معه حجم هائل من البيانات الوصفية مثل وقت النشر وتاريخه والموقع التقريبي للجهاز ونوعه وعدد الاعجابات وعدم الاعجاب والتعليقات واعادة النشر ومتابعة الحسابات او حظره هذه الطبقات المتعددة من البيانات تستفيد منها المؤسسات بطرق مختلفة فشركات التقنية تستخدمها لتدريب خوارزميات التوصية التي تقترح على كل مستخدم منشورات او حسابات تناسب اهتماماته وتعتمد شركات الاعلان على نفس البيانات لبناء اعلانات موجهة بدقة لاشخاص لديهم اهتمامات او سلوكيات معينة كما تلجأ بعض المنصات وفقا لشروط الاستخدام الى بيع بيانات مجمعة ومجهولة الهوية لشركات ابحاث السوق حتى تحلل اتجاهات الجمهور وتفضيلاته ويكفي ان نتخيل عدد التغريدات او المنشورات التي تنتج في دقائق قليلة على منصة عالمية واحدة لندرك اننا نتعامل مع تدفق مستمر من البيانات الجديدة على مدار الساعة ما يجعل وسائل التواصل الاجتماعي من اغنى مصادر البيانات التي يمكن استغلالها في تطبيقات الذكاء الاصطناعي لتحليل المشاعر وفهم اتجاهات الراي العام ورصد المواضيع الاكثر تداولاً في زمن قصير جدا



1.6.2-بيانات أنظمة نقاط البيع في المتاجر

في عالم تجارة التجزئة تعتبر **أنظمة نقاط البيع** الموجودة عند صناديق الدفع مصدرا أساسيا لبيانات دقيقة عن تعاملات الزبائن فكل مرة يمرر البائع منتجا على جهاز القراءة الضوئية ويسجل عملية الشراء يتم انشاء سجل يحتوي على رمز المنتج وسعره والكمية والخصم المطبق وطريقة الدفع ووقت العملية وربما رقم فرع المتجر والموظف المسؤول وعندما تجمع هذه السجلات على مستوى اليوم او الاسبوع تتحول **الى قاعدة بيانات غنية** يمكن استخدامها في اكثر من اتجاه فمن الناحية التشغيلية تغذي هذه البيانات أنظمة مراقبة المخزون بحيث يعرف النظام تلقائيا عدد القطع التي خرجت من كل صنف ويقارنها بالمستوى المطلوب فيقوم بانشاء طلبية جديدة عندما يقترب المخزون من حد معين وبهذا لا تنفد السلع من الرفوف ولا تتكدس بكميات كبيرة كما يستفيد قسم التسويق من بيانات نقاط البيع لتحليل المواسم التي يرتفع فيها الطلب على منتجات محددة ودراسة سلال المشتريات لمعرفة اي السلع تشتري معا كثيرا مما يساعد في تصميم عروض واماكن عرض اكثر ذكاء اما في مجال الذكاء الاصطناعي فيمكن بناء نماذج تتنبأ بالمبيعات المستقبلية لكل فرع اعتمادا على بيانات نقاط البيع التاريخية مع العوامل الزمنية مثل اليوم من الاسبوع والعطل الرسمية **فيتم التخطيط للموظفين والمخزون** بناء على توقعات علمية بدلا من التخمين



1.6.3- استغلال بيانات نقاط البيع وبطاقات الولاء في تجارة التجزئة بين الفائدة والخصوصية

عند دراسة بيانات نقاط البيع في متاجر التجزئة من المهم ان ندرك ان كل عملية شراء تنتج كما كبيرا من البيانات **لكن لا يمكن ولا يجوز الاحتفاظ** بكل ما يتم تداوله في لحظة الدفع فبيانات البطاقات البنكية مثل الرقم الكامل للبطاقة ورمز التحقق الموجود على ظهرها تعد بيانات شديدة الحساسية وتخضع لمعايير أمنية عالمية مثل معيار امن بيانات بطاقات الدفع **PCI DSS** هذه المعايير تفرض على التاجر ان يقلل قدر الامكان من تخزين هذه المعلومات وان يحمي ما يتم الاحتفاظ به بالتشفير وضوابط الوصول الصارمة حتى يتم تقليل مخاطر الاحتيال وسرقة البيانات ولا يسمح عادة بان تبقى هذه المعلومات الحساسة مخزنة كنص عادي يمكن لاي موظف الاطلاع عليه

الى جانب البيانات التي تنتج مباشرة من عملية البيع يستخدم كثير من تجار التجزئة وخاصة سلاسل السوبرماركت **بطاقات ولاء** تمنح للزبائن الدائمين عند التسجيل في برنامج الولاء يقوم الزبون بادخال بيانات شخصية مثل الاسم والعنوان والعمر وربما حجم الاسرة وعند استخدام البطاقة في كل زيارة للمحل ترتبط عملية الشراء بحساب هذا الشخص نفسه فيصبح بالامكان تتبع عاداته الشرائية مع مرور الوقت وتتحول البطاقة الى مفتاح يربط بين هوية الزبون وبين محتويات السلة وتكرار زيارته والايام التي يفضل التسوق فيها في المقابل يحصل الزبون على مزايا واضحة مثل خصومات على فواتيره امكانية الوصول الى عروض خاصة **لا تظهر لغير المشتركين** توصيات بمنتجات تناسب ما يشتريه عادة وقسائم خصم موجهة تم تصميمها بناء على تاريخه في الشراء

الجمع بين بيانات نقاط البيع وبيانات بطاقات الولاء خلق لدى **تجار التجزئة** ثروة معلوماتية لم تكن متاحة بنفس المستوى في الماضي فبدلا من معرفة اجمالي مبيعات منتج معين فقط يمكنهم اليوم ان يروا من يشتري هذا المنتج وفي اي فرع وفي اي وقت من السنة وباستخدام **خوارزميات التعلم الآلي** يمكن تحليل هذه البيانات لتقسيم الزبائن الى شرائح متشابهة في السلوك والتنبؤ بالمنتجات التي سترتفع

مبيعاتها في مواسم معينة وفي مناطق محددة وهذا يفسر لماذا نجد سلعا معينة متوفرة بكثرة في فرع من فروع السوبرماركت بينما تكاد تختفي من فرع اخر لان بيانات الماضي اظهرت ان الاقبال عليها في ذلك الحي ضعيف فيتم استبدالها بمنتجات اقرب لذوق سكان المنطقة ويمكن لنفس **الخوارزميات** ان تقترح حملات تسويقية مختلفة لكل شريحة من الزبائن بحيث تصل قسائم الخصم والعروض عبر التطبيق او البريد الالكتروني الى الاشخاص الاكثر احتمالا للاستفادة منها وبذلك يتحقق هدف التاجر في زيادة الربح واستقطاب زبائن جدد والحفاظ على ولاء الزبائن الحاليين

البيانات التي تمر في عملية الدفع نفسها يمكن النظر اليها على انها تنتمي الى مجموعات رئيسية مختلفة فهناك بيانات تعرف **حامل البطاقة** مثل الاسم والرقم وتاريخ انتهاء الصلاحية وهناك بيانات **تخص تفاصيل العملية** مثل المبلغ والعملة ووقت التنفيذ واسم المتجر ونوع النشاط التجاري وهناك بيانات امنية تستخدم للتحقق من البطاقة مثل رمز التحقق والبيانات الموجودة في الشريحة الذكية او في الشريط المغناطيسي واخيرا بيانات ناتجة عن عملية التفويض مثل رمز الموافقة او الرفض من جهة الاصدار ومع ان هذه المجموعات كلها تشكل صورة متكاملة عن المعاملة الا ان درجة حساسيتها ليست واحدة فبعضها يمكن الاحتفاظ به في سجلات المحاسبة لاجراء المراجعات لاحقا بينما يجب حماية الاجزاء الاكثر حساسية او عدم تخزينها اصلا الا في صورة مشفرة او في انظمة متخصصة تلتزم بالكامل بالمعايير الامنية



كل هذه الأنشطة في جمع البيانات وتحليلها لا تتم في فراغ قانوني بل تخضع في العادة لقوانين حماية البيانات في كل بلد ففي الاتحاد الاوروبي مثلا توجد اللائحة العامة لحماية البيانات التي تفرض على الشركات ان تكون شفافة مع الزبون بشأن ما تجمعها من معلومات ولماذا تجمعها وكم من الوقت تحتفظ بها كما تلزمها باتخاذ اجراءات فنية وتنظيمية لحماية الخصوصية ومنح الافراد حقوقا مثل طلب الاطلاع على بياناتهم او تصحيحها او حذفها وتوجد في دول اخرى تشريعات مشابهة تفرض على تجار التجزئة ان يعاملوا البيانات الشخصية بحذر وامان وان يوازنوا بين رغبتهم في استخدام هذه البيانات لتحسين الخدمات وتحقيق الارباح وبين احترام حقوق الافراد في الخصوصية وعدم اساءة استخدام معلوماتهم

فيديوهات شرح :

<https://www.youtube.com/watch?v=sDf0dKypBeY>

<https://www.youtube.com/watch?v=vTkiYpSzfLA>

<https://www.youtube.com/watch?v=xYW4mqpQbjc>

<https://www.youtube.com/watch?v=UuplwhCIKic>

<https://www.youtube.com/watch?v=OgA6WpnAtz0>

1.7 أنظمة التجارة الإلكترونية وانترنت الاشياء كمصادر رئيسية لبيانات تدعم تطبيقات الذكاء الاصطناعي

تعد أنظمة التجارة الإلكترونية شكلا من اشكال التجارة يعتمد كليا او جزئيا على الانترنت بدلا من زيارة المتجر الفعلي فقط فالمستخدم يدخل الى موقع او تطبيق خاص بالمتجر يختار المنتجات او الخدمات ثم يدفع إلكترونيا ويتم توصيل الطلب اليه وخلال هذه الرحلة البسيطة ظاهريا يتولد كم هائل من البيانات في كل خطوة مثل المنتجات التي تمت مشاهدتها والمنتجات التي اضيفت الى سلة التسوق وما تم شراؤه فعلا ووسيلة الدفع ومكان التوصيل وزمن الطلب هذه البيانات لا تستخدم فقط لاكمال العملية بل تحفظ وتحلل في مستويات مختلفة من التخطيط فادارة الشركة تستفيد منها استراتيجيا لتحديد المنتجات التي يجب تطويرها او ايقافها وتقدير الاسواق الجديدة التي يمكن دخولها وعلى المستوى التشغيلي تستخدم لفهم قنوات التسويق التي تجذب اكبر عدد من الزبائن واختيار الدول او المدن التي ينبغي التوسع فيها وعلى المستوى اليومي تساعد في ادارة المخزون وجدولة الموظفين وتخطيط مسارات التوصيل حسب حالة الطقس والازدحام وكل ذلك يمكن تعزيزه بخوارزميات ذكاء اصطناعي تتنبأ بالطلب وتضبط الخطط بشكل مستمر

تدعم منصات التجارة الإلكترونية اكثر من نمط واحد للمعاملات بين مختلف الاطراف ففي النمط الشائع بين الشركة والمستهلك المعروف باسم **B2C** يشتري الافراد مباشرة من المتاجر الإلكترونية او منصات البث والاشتراك الرقمي فيحصلون على مرونة في التسوق على مدار الساعة دون التقيد بساعات عمل المتجر وفي نمط **B2B** تتبادل الشركات فيما بينها السلع والخدمات عبر بوابات التجارة الإلكترونية مثل بيع المصنع لبضائعه الى سلسلة متاجر او تعاقد شركة صغيرة مع مزود خدمات لوجستية عبر منصة مخصصة ويختصر ذلك كثيرا من الاجراءات الورقية ويجعل تحديث الاسعار والكميات اكثر سرعة كما يوجد نمط **C2C** حيث يبيع الافراد لبعضهم بعضا مثل منصات بيع الاغراض المستعملة او الاعمال اليدوية فيعرض شخص اغراض اطفاله التي لم يعد يحتاجها ويشترىها شخص اخر بسعر منخفض واخيرا هناك نمط **C2B** حيث يقدم الافراد خدماتهم او محتواهم الى الشركات مقابل مقابل مادي مثل المصورين او صانعي المحتوى الذين يبيعون صورهم واعمالهم الابداعية لشركات اعلامية او تسويقية هذه الانماط المختلفة تنتج صوراً متنوعة من البيانات حول طريقة تفاعل الافراد والشركات في البيئة الرقمية



لكي تعمل كل هذه المعاملات بسلاسة تحتاج الشركات الى منصات تجارية إلكترونية قوية وأمنة توفر خدمات أساسية مثل عرض المنتجات بشكل منظم وبحث متقدم وسلة تسوق قابلة للحفظ وطرق دفع آمنة تتوافق مع معايير حماية بيانات البطاقات كما تحتاج الى وحدات لإدارة الطلبات والمخزون والتقارير وبعض الشركات الكبيرة تطور منصاتهما من الصفر لتناسب احتياجاتها الخاصة بينما تعتمد كثير من المؤسسات الصغيرة والمتوسطة على حلول جاهزة يمكن استضافتها أو الاشتراك بها كخدمة سحابية فتستفيد من البنية الآمنة والدعم الفني دون الحاجة الى فريق تقني ضخم وفي الحالتين تكون البيانات الناتجة عن معاملات الزبائن هي المحرك الأساسي الذي يغذي أنظمة التحليل والذكاء الاصطناعي داخل هذه المنصات

اما إنترنت الأشياء فهو مصطلح يشير الى شبكة واسعة من الأجهزة اليومية المزودة بحساسات واتصال بالإنترنت بحيث تستطيع جمع بيانات من البيئة المحيطة وإرسالها الى أنظمة أخرى لمعالجتها يمكن ان يكون هذا الجهاز آلة صناعية كبيرة في مصنع تسجل درجة حرارة المحرك واهتزازاته أو عدادا ذكيا في مبنى يقيس استهلاك الكهرباء كل دقائق أو جهازا صغيرا قابلا للارتداء مثل سوار رياضي يتابع عدد الخطوات ومعدل ضربات القلب في كل الحالات تكون الأجهزة مجهزة بحساسات تلتقط القياسات وبرنامج صغير يتحكم في طريقة التخزين والارسال وغالبا ما يتم تمرير هذه البيانات الى مكونات تعتمد على الذكاء الاصطناعي والتعلم الآلي كي تحلل الانماط وتتعرف على السلوك الطبيعي وغير الطبيعي وتصدر تنبيهات أو توصيات لتحسين الاداء مثل تقليل استهلاك الطاقة أو جدولة صيانة وقائية قبل وقوع عطل كبير

كل جهاز متصل ضمن بيئة إنترنت الأشياء يعد مصدر بيانات قائما بذاته فلو نظرنا الى نظام امان منزلي ذكي على سبيل المثال سنجد ان كل عملية تفعيل أو الغاء للتنبيه تسجل مع التاريخ والوقت وقد يرتبط ذلك بمعرف المستخدم الذي ادخل رمز المرور كما يمكن للنظام ان يسجل الغرف التي تم استثناء اجهزتها من التنبيه لوجود حيوانات اليفة فيها وبهذا تتكون سلسلة زمنية من الاحداث يمكن تحليلها لاحقا لاكتشاف محاولات الدخول غير المعتادة أو للتحقق من الالتزام باجراءات الامان وفي مثال اخر تجمع الساعة الذكية بيانات مفصلة عن نشاط صاحبها طول اليوم مثل نوع التمرين ومدته وعدد السعرات المحروقة وفي الأجهزة المتقدمة يتم تسجيل مؤشرات مثل معدل نبض القلب وتشبع الاكسجين في الدم وحتى مستوى الضوضاء المحيطة وتخزن هذه البيانات في الساعة ثم تنقل الى الهاتف أو الحاسوب

لنعرض للمستخدم او ترسل الى تطبيقات صحية متخصصة وهنا يظهر جانب مهم هو الخصوصية اذ يجب على الشركات المصممة لهذه الاجهزة ان تضمن تشفير البيانات وحمايتها وعدم مشاركتها مع اطراف اخرى الا بموافقة المستخدم الصريحة لان مزايا انترنت الاشياء في تحسين الراحة وجودة الحياة لا تلغي الحاجة الى ضوابط واضحة تحافظ على امن البيانات الشخصية وسريتها

فيديوهات شرح :

https://www.youtube.com/watch?v=ZTd_7UZEb2Y

<https://www.youtube.com/watch?v=-TCwZ3fNf6M>

<https://www.youtube.com/watch?v=q4mjkygbeFs>

1.8 المساعدون الازكياء واجهزة انترنت الاشياء المنزلية والصحية والمرورية كمصادر بيانات لانظمة الذكاء الاصطناعي



مقدمة عامة

مع تطور التقنيات الرقمية لم يعد الذكاء الاصطناعي موجودا فقط داخل مراكز البيانات او في برامج متخصصة بل اصبح جزءا من تفاصيل الحياة اليومية في المنزل والسيارة والمكتب وحتى على معصم اليد من خلال الساعات والاساور الذكية كل هذه الاجهزة المتصلة بالانترنت يطلق عليها اسم انترنت الاشياء وهي لا تكتفي بتنفيذ اوامر بسيطة بل تولد كما هائلا من البيانات التي يمكن جمعها وتحليلها لتطوير انظمة ذكاء اصطناعي اكثر ذكاء ودقة

في هذا الجزء سوف نتعرف بشكل مفصل على اربعة امثلة رئيسية لاجهزة انترنت الاشياء التي تعد اليوم من اهم مصادر البيانات لمشروعات الذكاء الاصطناعي

المساعدون المنزليون الازكياء
انظمة التدفئة المنزلية الذكية
اجهزة مراقبة الصحة القابلة للارتداء
المركبات والانظمة المرورية الذكية

وسوف ترى كيف يتحول كل تفاعل بسيط مع هذه الأجهزة الى سجلات بيانات يمكن استخدامها في تحسين جودة الخدمات وزيادة كفاءة استهلاك الطاقة ورفع مستوى السلامة والصحة مع الانتباه في الوقت نفسه الى قضايا الخصوصية والامن

1.8.1 المساعدون الأذكىاء كمصدر دائم للبيانات

• الفكرة العامة:

- المساعد المنزلي الذكي ليس مجرد "سبيكر" يرد على الأسئلة.
- هو نظام متكامل يجمع بيانات باستمرار من تفاعل المستخدمين ويحوّلها إلى سجلات بيانات تستخدم في تطوير نماذج الذكاء الاصطناعي.

1.8.2 آلية عمل المساعد المنزلي الذكي

مكونات المساعد المنزلي

- جهاز صغير يوضع في:
- غرفة المعيشة، أو
- المكتب.
- يحتوي عادة على:
- مكبر صوت (Speaker).
- ميكروفونات.
- معالج بسيط.
- اتصال بالإنترنت عبر شبكة المنزل.

ما يراه المستخدم VS ما يحدث في الخلفية

- ظاهرياً:
- صندوق يمكن أن:
- يجيب عن حالة الطقس.
- يشغل أغنية.
- يطفى الأنوار... إلخ.
- في الخلفية:
- توجد سلسلة خطوات تقنية معقدة تعتمد على الذكاء الاصطناعي والحوسبة السحابية.

1.8.3 سلسلة الخطوات التقنية (من الصوت إلى الاستجابة)

- عندما يقول المستخدم كلمة التنبيه:
- يلتقط الميكروفون الكلام.
- يحوّل الكلام إلى إشارة رقمية.
- تُرسل الإشارة إلى خوادم سحابية.

- تستخدم الخوادم نماذج متقدمة للتعرف على الكلام لتحويل الصوت إلى نص مكتوب.
- يدخل النص إلى طبقة أخرى من نماذج فهم اللغة الطبيعية:
 - لتحديد نوع طلب المستخدم:
 - سؤال معلوماتي؟
 - أمر للتحكم في جهاز منزلي؟
 - طلب تشغيل وسائط؟
 - بناءً على نوع الطلب:
 - إذا كان تحكمًا في الأجهزة المنزلية:
 - يرسل المساعد أوامر إلى:
 - اللمبات الذكية.
 - المكيفات.
 - الستائر الذكية.
 - أجهزة أخرى على الشبكة نفسها.
 - إذا كان سؤالًا عن معلومة:
 - يتم الاستعلام من:
 - قاعدة بيانات، أو
 - خدمة ويب (Web Service) مناسبة.
 - صياغة جواب نصي.
 - تحويل الجواب مرة أخرى إلى صوت مسموع يعود للمستخدم خلال ثوانٍ.
 - ملاحظة مهمة:
 - هذه السلسلة من التحويلات:
 - صوت → إشارة رقمية → نص → فهم لغوي → قرار → صوت مرة أخرى
 - هي تطبيق عملي مباشر وقوي للذكاء الاصطناعي في الحياة اليومية.

1.8.4 نوعية البيانات التي يسجلها المساعد الذكي

نظرة المستخدم VS نظرة أنظمة الذكاء الاصطناعي

- من وجهة نظر المستخدم:
 - العملية تبدو حوارًا بسيطًا وسريعًا.
 - من وجهة نظر أنظمة الذكاء الاصطناعي:
 - كل تفاعل يتحول إلى سجل بيانات غني يحتوي على تفاصيل متعددة.

عناصر السجل الذي يتم تكوينه

يمكن أن تحتوي سجلات التفاعل على العناصر التالية:

- وقت التفاعل وتاريخه.
- نوع الطلب:

- سؤال معلوماتي؟
- أمر تشغيل/إيقاف؟
- طلب تذكير؟
- مضمون العبارة النصية:
- بعد تحويل الصوت إلى نص.
- الاستجابة التي قَدَّمها النظام:
- وما إذا تم تنفيذها بنجاح أم لا.
- نوع الجهاز أو الخدمة التي تم التحكم بها في المنزل:
- لمبة، مكيف، ستارة، تلفاز... إلخ.
- المدة الزمنية:
- بين سماع الأمر وإعادة الاستجابة للمستخدم.
- رد فعل المستخدم:
- هل قِيم الإجابة؟
- هل أضاف ملاحظة أو طلبًا إضافيًا؟

كيف تُستخدم هذه السجلات؟

- تُحفظ عادة في خوادم الشركة:
- لفترات مختلفة حسب سياسة الخدمة.
- تُستخدم من أجل:
- تدريب نماذج جديدة للتعرف على الكلام.
- تحسين فهم اللهجات المختلفة.
- توسيع قدرة النظام على فهم تعبيرات متعددة لنفس الطلب.

1.8.5 حلقة التغذية الراجعة وتحسين النماذج

ما هي حلقة التغذية الراجعة؟

- هي عملية رجوع نتائج الاستخدام الواقعي إلى النظام كي يستفيد منها في التطوير.
- تجعل النظام يتعلم من أخطائه ومن أنماط استخدام الناس في الحياة اليومية.

مثال على استخدام التغذية الراجعة

- إذا لاحظ النظام أن:
- نوعًا معينًا من الأسئلة يتكرر كثيرًا.
- وأصحاب هذه الأسئلة لا يحصلون على إجابات مرضية:
- يمكن لفريق التطوير:
- تحديث قاعدة المعرفة.
- تعديل نموذج فهم اللغة الطبيعية.
- تحسين طريقة التعامل مع هذا النوع من الأسئلة مستقبلاً.

تعلم تعبيرات جديدة ولهجات مختلفة

- يمكن للنظام دراسة:
- العبارات التي لم يفهمها في المرة الأولى.
- ثم فهمها بعد أن يعيد المستخدم صياغتها.
- بهذه الطريقة:
- يتعلم النظام تعبيرات ولهجات وألفاظ جديدة لنفس المعنى.
- ومع مرور الوقت:
- يتحول المساعد المنزلي من أداة بسيطة إلى نظام ذكي:
- يفهم المستخدمين في بلدان مختلفة.
- بدقة أعلى بكثير.
- هذه هي قيمة البيانات الواقعية التي تولد أثناء الاستخدام اليومي.

1.8.7 فوائد هذه البيانات وتحديات الخصوصية

فوائد بيانات المساعد المنزلي

تساعد بيانات المساعد المنزلي على تحقيق عدة أهداف، مثل:

- تحسين دقة التعرف على الكلام:
- خصوصًا في البيئات المليئة بالضوضاء.
- فهم العادات اليومية للمستخدمين:
- لبناء روتينات آلية مثل:
- إطفاء الأنوار في وقت محدد كل يوم.
- تشغيل موسيقى معينة في بداية اليوم أو نهايته.
- تطوير خدمات جديدة:
- بناء على الأسئلة المتكررة التي يطرحها الناس في بلد معين أو فئة معينة.

الجانب الحساس: الخصوصية

- التسجيلات الصوتية.
- تواريخ الاستخدام.
- مواقع الأجهزة.

تُعتبر من أكثر أنواع البيانات حساسية؛ لأنها:

- تكشف نمطًا واضحًا لحياة الأشخاص اليومية:
- أوقات وجودهم في البيت.
- عادات النوم والاستيقاظ.
- الأجهزة التي يستخدمونها باستمرار.

متطلبات حماية الخصوصية

لذلك يجب أن تكون هناك سياسات واضحة تضمن للمستخدم:

- القدرة على:
- مراجعة ما تم تسجيله عنه.
- حذف السجلات إذا أراد.
- تحديد ما إذا كان يقبل:
- استخدام بياناته في تدريب النماذج.
- أو يفضل عدم استخدامها لهذا الغرض.

ثالثاً: جدول يوضح أنواع البيانات التي يسجلها المساعد الذكي

نوع البيانات	الوصف المختصر	مثال عملي من الاستخدام اليومي
وقت التفاعل وتاريخه	متى تم إصدار الأمر أو السؤال	10:35 مساءً – 2025/12/1
نوع الطلب	تصنيف الطلب: سؤال، تشغيل، إيقاف، تذكير...	“ما حالة الطقس؟” / “اطفي الأنوار” / “ذكرني بالدواء”
مضمون العبارة النصية	النص الناتج بعد تحويل الصوت إلى نص	“شغل قائمة الأغاني المفضلة”
الاستجابة ونتيجة التنفيذ	ما الرد الذي أعطاه النظام وهل نُفذ الأمر بنجاح	تشغيل الأغنية فعلاً أو فشل التنفيذ
نوع الجهاز أو الخدمة المتحكم بها	اسم أو نوع الجهاز الذي استقبل الأمر	لمبة الصالون، مكيف غرفة النوم، التلفاز
المدة الزمنية بين الأمر والاستجابة	الزمن بين سماع المساعد للأمر وإرجاع الاستجابة	نصف ثانية، ثانية واحدة، ثانيتان...
رد فعل المستخدم	تقييم المستخدم أو ملاحظاته بعد الاستجابة	“شكراً”، تقييم بنجوم، أو ملاحظة “هذا غير صحيح”

رابعاً: جدول يربط بين فوائد البيانات وتحديات الخصوصية

الجانب	الفائدة/التحدي	مثال توضيحي	ما المطلوب؟
تحسين دقة التعرف	فهم الكلمات في وجود ضوضاء وخلفيات مختلفة	فهم الأوامر في مطبخ مزدحم أو غرفة فيها تلفاز يعمل	جمع بيانات متنوعة مع مراقبة الاستخدام
بناء الروتين	التعرف على العادات اليومية للمستخدمين	إطفاء الأنوار تلقائياً عند منتصف الليل	استخدام البيانات لتسهيل الحياة لا للتتبع المفرط
تطوير الخدمات	اكتشاف الأسئلة الأكثر تكراراً لإنشاء خدمات جديدة	أسئلة كثيرة عن حركة المرور في مدينة معينة	تحليل مجهول الهوية قدر الإمكان

حماية الخصوصية	البيانات شديدة الحساسية عن حياة الأشخاص اليومية	كشف أوقات وجود المستخدم في البيت أو خارجه	سياسات واضحة، خيارات مراجعة وحذف، موافقة صريحة
----------------	---	---	--

1.9 أنظمة التدفئة المنزلية الذكية كعين ترصد حياة البيت

1.9.1 مكونات النظام والبيانات التي يجمعها

انظمة التدفئة الذكية هي مثال آخر على كيف يمكن لجهاز بسيط الظاهر ان يتحول الى مصدر بيانات غني يتكون النظام عادة من ترموستات مركزي متصل بالانترنت مع مجموعة من الحساسات في الغرف المختلفة تقيس درجة الحرارة والرطوبة وربما حركة الاشخاص في المكان

كل حساس يرسل قراءاته كل بضع دقائق الى وحدة التحكم هذه القراءات يمكن ان تتضمن

درجة الحرارة الحالية في الغرفة

نسبة الرطوبة

وقت القياس وتاريخه


اشارة عن وجود حركة او عدمها في الغرفة

ومع مرور الايام تتكون سلسلة زمنية من البيانات تظهر كيف تتغير درجات الحرارة داخل البيت على مدار اليوم والفصول وكيف يرتبط ذلك بوجود افراد العائلة في المنزل

1.9.2 استخدام الذكاء الاصطناعي لفهم الانماط

بدلا من الاعتماد على جدول ثابت للتشغيل والايقاف يمكن استخدام نماذج تعلم آلي لتحليل هذه السلاسل الزمنية فيتعلم النظام مثلا ان اهل البيت يغادرون صباحا في وقت محدد ويعودون بعد الظهر وان غرفا معينة تبقى غير مستخدمة في اغلب الايام فيعيد ضبط حرارة تلك الغرف لتكون اقل في الاوقات التي لا يستخدمها احد

يمكن ايضا للنظام توقع الحاجة للتدفئة قبل حدوثها فمثلا اذا كان الجو باردا خارج المنزل ويتوقع تطبيق الطقس انخفاض اضافيا في الليل يستطيع النظام رفع درجة الحرارة قليلا قبل عودة افراد العائلة بحيث يجدون الجو مناسباً عند الوصول من غير حاجة لانتظار التسخين وقتا طويلا




ترشيد استهلاك الطاقة وتقليل التكلفة

من خلال هذه القرارات الذكية يمكن لـ **الأنظمة التدفئة** تقليل العمل في **الافاق غير الضرورية** مثل ابقاء التدفئة في مستوى منخفض عندما يكون المنزل خاليا او عند النوم مع الحفاظ على درجة مقبولة من الراحة النتيجة هي تخفيض استهلاك الوقود او الكهرباء وتقليل الفاتورة الشهرية وفي الوقت نفسه تقليل الانبعاثات الضارة بالبيئة

حساسية بيانات الحركة داخل المنزل

كما في حالة المساعدين الانكفاء تحمل بيانات التدفئة الذكية جانبا حساسا فهي تكشف اوقات وجود الاشخاص في البيت وغياهم والغرف التي يستخدمونها اكثر من غيرها وهذه معلومات يمكن ان تكون خطرة اذا وقعت في يد جهة غير موثوقة لذلك تخضع هذه الانظمة عادة لتدابير امنية مثل التشفير وتقييد صلاحيات الوصول وينبغي على المستخدمين فهم اعدادات الخصوصية جيدا قبل مشاركة البيانات مع اطراف خارجية مثل شركات الطاقة او مزودي الخدمات

٣ ترشيد استهلاك الطاقة وتقليل التكلفة



٤ حساسية بيانات الحركة داخل المنزل



1.10 الأجهزة الصحية القابلة للارتداء بين العادة اليومية والطب الذكي

ما الذي تقيسه الساعات والاساور الذكية

الأجهزة القابلة للارتداء مثل الساعات الذكية واسوارات اللياقة أصبحت شائعة جدا بين الشباب وموظفي المكاتب والرياضيين هذه الأجهزة تحتوي على حساسات صغيرة تقيس عدة مؤشرات من بينها

عدد الخطوات التي يقطعها الشخص كل يوم
معدل نبض القلب لحظيا وعلى مدار اليوم
السرعات الحرارية التقديرية التي حرقها المستخدم
مدة النوم وجودته وتوزيع فتراته

وفي الأجهزة المتقدمة نسبة تشبع الدم بالأكسجين ومستوى الضوضاء المحيطة
وأحيانا بيانات موقع تقريبية من خلال نظام تحديد المواقع

تجمع هذه البيانات بشكل مستمر وتخزن محليا على الجهاز ثم ترسل الى الهاتف المحمول ومنه الى خدمة سحابية اذا وافق المستخدم على ذلك

٢ استخدام البيانات على مستوى الفرد

على مستوى الفرد يستطيع صاحب الجهاز استخدام هذه البيانات لمراقبة نمط حياته فاذا اكتشف انه لا يصل الى عدد الخطوات الموصى به في اليوم يمكنه تعديل برنامج اليوم لتضمين المزيد من الحركة كما يمكنه مقارنة ايام الاسبوع ببعضها لمعرفة هل يبذل جهدا اكثر في بداية الاسبوع ام نهايته وتحليل علاقتها بجودة النوم ومستوى الطاقة

كذلك يمكن للشخص الذي يتبع نظاما غذائيا معين ان يراقب الوزن والسرعات والتمارين معا ليكون قراره مبنيًا على بيانات وليس على شعور عام فقط

استخدام البيانات في المتابعة الطبية

عندما **يسمح المستخدم** بمشاركة هذه البيانات مع طبيب او مركز صحي تصبح الاجهزة القابلة للارتداء اداة مساعدة مهمة في متابعة الامراض المزمنة فمثلا في حالة اضطراب نبض القلب يمكن للطبيب مراجعة سجل النبض على مدار اسابيع وليس فقط اثناء الزيارة القصيرة في العيادة

في حالات اخرى مثل السكري من النوع الاول او الثاني يمكن ربط هذه الاجهزة بحساسات خاصة لقياس مستوى السكر في الدم لحظيا ليصبح لدى المريض والطبيب معا صورة دقيقة عن تفاعل الجسم مع الطعام والنشاط والدواء

دور الذكاء الاصطناعي في التنبؤ والمراقبة

الكم الهائل من القياسات الذي تنتجه هذه الاجهزة **يجعلها مثالية لاستخدام نماذج تعلم آلي** تتعامل مع السلاسل الزمنية يمكن لمثل هذه النماذج اكتشاف انماط دقيقة يصعب على الانسان رؤيتها مثل تكرار ارتفاع بسيط في نبض القلب قبل شعور المريض بالتعب بساعات او ارتباط نوع معين من النشاط باضطراب في النوم

عند اكتشاف نمط مقلق يمكن للنظام ارسال تنبيه مبكر على الساعة نفسها او الى تطبيق الهاتف وربما الى الطبيب في الحالات الحرجة مثل احتمال هبوط حاد في السكر او ارتفاع خطير في النبض هذه القدرة على التنبؤ قبل وقوع الازمة الفعلية قد تنقذ حياة شخص او تمنع تدهور حالة صحية على المدى الطويل



التوازن بين الفائدة وحماية الخصوصية

في المقابل تعد بيانات الصحة الشخصية من أكثر ما يجب حمايته فالسجلات التي تحتوي على نبض القلب وجودة النوم وامراض مزمنة لا ينبغي ان تنتشر دون ضوابط واضحة لذلك تشترط القوانين في كثير من الدول موافقة صريحة من الشخص قبل استخدام بياناته في الابحاث او التدريب كما تلزم الشركات بتوفير وسائل لاختفاء هوية المستخدمين عند تحليل البيانات على مستوى جماعي

1.11 المركبات والأنظمة المرورية الذكية كمصدر ضخم للبيانات

- المركبات الحديثة (خصوصية وتجارية) تحولت إلى:
- منصات حساسات (Sensors Platforms) متصلة بالإنترنت.
- ترسل بيانات مستمرة عن موقع المركبة، حالتها، وسلوك السائق.
- هذه البيانات تُستخدم:
- في إدارة الأسطول.
- دعم السائق في الوقت الفعلي.
- تقييم المخاطر والتأمين.
- التخطيط للصيانة.
- وتحمل أبعاداً أمنية وأخلاقية مهمة.

بيانات الموقع والحركة في المركبات الحديثة

1.11.1 أنواع البيانات التي تجمعها المركبات

- الموقع الجغرافي الدقيق للمركبة أثناء الحركة.
- السرعة:
- السرعة الحالية.
- السرعة المتوسطة.
- السرعة الدنيا والقصوى.
- التسارع والتباطؤ الحاد:
- مؤشرات على قيادة خطيرة أو استخدام المكابح بعنف.
- استهلاك الوقود:
- كمية الوقود المستهلك.
- المسافة المقطوعة بين كل تعبئة وأخرى.
- حالة مكونات السيارة:
- حرارة المحرك.

- مستوى الزيت.
- مؤشرات أعطال أخرى حسب نوع السيارة.

1.11.1 الفرق بين السيارات العادية وشاحنات النقل

- في شاحنات النقل والحافلات لمسافات طويلة:
- البيانات تكون متوفرة شبه لحظية (Real-time) تقريبًا.
- الشركة المالكة تستطيع:
- رؤية موقع كل مركبة على الخريطة.
- متابعة سلوك السائق (سرعة، وقفات، تجاوزات).
- تقدير الوقت المتوقع للوصول للعملاء.

1.11.2 دعم السائق والمستفيد النهائي

- تطبيقات الملاحة الذكية تساعد السائق في:
- اختيار أفضل مسار بناءً على:
- بيانات كثافة المرور من آلاف الأجهزة.
- تجنب الطرق المزدحمة أو المغلقة.
- في حالة الحوادث أو إغلاق الطرق:
- إذا بلغ عدد من المستخدمين عن حادث في طريق معين:
- يقوم النظام بـ:
- إعادة حساب زمن الوصول.
- اقتراح طريق بديل.
- يمكن إرسال المعلومات بشكل آلي إلى:
- أفراد العائلة.
- أو جهات تنتظر وصول السائق.
- الهدف:
- طمأننتهم حول وقت الوصول المتوقع – (Estimated Time of Arrival – ETA).

1.11.3 تقييم سلوك القيادة وتحديد أسعار التأمين

- بعض شركات التأمين تستخدم بيانات المركبة لـ:
- تحليل سلوك القيادة الفعلي بدل الاعتماد فقط على:
- عمر السائق.
- نوع السيارة.
- السائق الذي يظهر:
- نمط قيادة هادئ.
- سرعة ضمن الحدود.

- تسارع وتباطؤ سلس.
- التزام بالمسارات.
- → يحصل على تخفيض في قيمة التأمين.
- السائق الذي:
- يقود بسرعة عالية.
- يضغط المكابح بقوة وبشكل متكرر.
- → يُصنّف أكثر خطورة، فيُرفع سعر التأمين عليه.
- هذه السياسة تعتمد على:
- تحليل بيانات حقيقية (Usage-based Insurance) بدل التقدير العام.

1.11.4 الصيانة الاستباقية للمركبات

- باستخدام بيانات مثل:
- استهلاك الوقود.
- حرارة المحرك.
- بيانات حساسات أخرى.
- يمكن لشركات النقل أن تستخدم نماذج ذكاء اصطناعي لـ:
- التنبؤ بموعد الحاجة إلى صيانة قبل حدوث العطل الفعلي:
- مثلاً:
- زيادة غير معتادة في استهلاك الوقود.
- ارتفاع طفيف ومتكرر في حرارة المحرك.
- عند اكتشاف نمط غير طبيعي:
- يرسل النظام تنبيه إلى قسم الصيانة لفحص المركبة في أقرب فرصة.
- فوائد الصيانة الاستباقية:
- تقليل احتمال تعطل الشاحنة على الطريق.
- الحفاظ على مستوى ثابت من الخدمة.
- تقليل التكاليف الناتجة عن الأعطال المفاجئة.


1.11.5 البعد الأمني والأخلاقي في بيانات المركبات

- مخاطر البيانات:
- تكشف تفاصيل عن:
- تحركات الأشخاص.
- الأماكن التي يزورونها.
- ساعات وجودهم في البيت أو العمل.
- المتطلبات القانونية والأخلاقية:
- التشريعات الحديثة تطالب الشركات بـ:
- توضيح نوعية البيانات التي يتم جمعها من المركبات.
- شرح طريقة تخزينها.

- توضيح الجهات التي يمكن مشاركة البيانات معها.
- في بعض الحالات: الحصول على موافقة صريحة من السائق قبل تفعيل التتبع المستمر.
- الهدف:
- موازنة الفائدة العملية مع حماية خصوصية الأفراد.

1.11.6 خاتمة عامة (ربط بين الأمثلة الأربعة)

- الأمثلة الأربعة في الوحدة:
 - المساعدون الأذكياء.
 - أنظمة التدفئة الذكية.
 - الأجهزة الصحية القابلة للارتداء.
 - المركبات والأنظمة المرورية الذكية.
- ليست مجرد أدوات رفاهية:
 - بل شبكات متكاملة من الحساسات ومولدات البيانات.
 - تغذي أنظمة الذكاء الاصطناعي بتيار مستمر من المعلومات الواقعية.
- فوائد هذه البيانات:
 - تحسين كفاءة استهلاك الطاقة في المنازل.
 - تطوير خدمات صحية أكثر دقة.
 - رفع مستوى سلامة النقل.
 - تقديم تجارب استخدام شخصية تناسب تفضيلات كل فرد.
- التحديات المقابلة:
 - حماية الخصوصية.
 - ضمان أمن البيانات.
 - منع استخدام البيانات بطرق تضر بالمستخدمين.
 - مهارة طالب الذكاء الاصطناعي وإنترنت الأشياء:
 - لا تقتصر على بناء نموذج قوي.
 - تشمل أيضاً:
 - اختيار مصادر البيانات بعناية.
 - تحليل البيانات بشكل نقدي.
 - تطبيق الضوابط الأخلاقية والقانونية.
- الهدف النهائي:
 - أن تكون هذه التقنيات في خدمة الإنسان لا العكس.



ثالثاً: جدول ملخص لبيانات المركبات الذكية واستخداماتها

المجال	نوع البيانات المستخدمة	ماذا يستفيد النظام؟	مثال تطبيقي
تتبع الحركة	الموقع الجغرافي، السرعة، التسارع	معرفة موقع المركبة، مراقبة الالتزام بالسرعة	تتبع شاحنة نقل على طريق سريع
دعم السائق	بيانات كثافة المرور من آلاف الأجهزة	اختيار أفضل مسار، حساب زمن الوصول، اقتراح طرق بديلة	تغيير المسار بعد حادث مفاجئ
التأمين المبني على الاستخدام	السرعة، التسارع، التباطؤ، نمط القيادة	تقييم سلوك القيادة الحقيقي وتحديد سعر التأمين	تخفيض التأمين لسائق هادئ
الصيانة الاستباقية	حرارة المحرك، استهلاك الوقود، بيانات حساسات أخرى	التنبؤ بالأعطال قبل حدوثها، تقليل التوقف المفاجئ	تنبيه للصيانة بعد زيادة استهلاك الوقود
الخصوصية والأمان	مسارات الحركة، أوقات الوجود في أماكن محددة	الالتزام بالقوانين، حماية خصوصية السائقين	طلب موافقة السائق قبل التتبع المستمر

• لمشاهدة مثال مرئي ممتع عن إنترنت الأشياء وكيف تُجمع البيانات منه، شاهد هذا الفيديو: [إنترنت الأشياء](#)

1.12 المقارنة بين البيانات النوعية والبيانات الكمية في مشاريع الذكاء الاصطناعي



مقدمة عامة

عند العمل في اي مشروع **الذكاء الاصطناعي** أو **التعلم الآلي** لن يكون السؤال الاول هو ما هي الخوارزمية التي سأستخدمها بل ما نوع البيانات التي سيتعلم منها النموذج وما طبيعتها وكيف تم جمعها من العالم الحقيقي هنا يظهر الفرق الجوهرى بين نوعين رئيسيين من البيانات هما البيانات النوعية والبيانات الكمية وكل نوع منهما يحمل طريقة مختلفة في التعبير عن الواقع وبالتالي يؤثر في تصميم المشروع ونتائجه وطريقة تفسير مخرجاته

البيانات الكمية تقدم صورة رقمية قابلة للقياس مثل **عدد مرات زيارة موقع معين** أو **نسبة النجاح** في اختبار أو قيمة فاتورة شهرية أما البيانات النوعية فتركز على التجربة الانسانية وما يرتبط بها من آراء ومشاعر واسباب ودوافع مثل شكاوى المواطنين من خدمة معينة أو وصف مريض لشعوره بعد العلاج أو تعليق طالب على اسلوب شرح معلمه مشاريع الذكاء الاصطناعي الحديثة الناجحة هي تلك التي تفهم هذا الفرق وتعرف متى تستخدم كل نوع ومتى تمزج بينهما للحصول على صورة اقرب للواقع

1.12.1 تعريف البيانات الكمية في سياق الذكاء الاصطناعي

البيانات **الكمية** هي كل معلومة يمكن التعبير عنها باستخدام **أعداد** يمكن جمعها وطرحها ورسمها وحساب المتوسط والانحراف المعياري لها في مشاريع الذكاء الاصطناعي تستخدم هذه البيانات بكثرة لأن **معظم الخوارزميات القياسية تتعامل طبيعياً مع الجداول الرقمية**

من امثلة البيانات الكمية في تطبيقات حقيقية:

عدد الطلبات اليومية في متجر الكتروني لكل يوم من ايام الاسبوع
مدة بقاء المستخدم داخل تطبيق الهاتف محسوبة بالدقائق
درجة الطالب في اختبار من مئة
ضغط الدم أو نسبة السكر في دم مريض مقاسة بوحدة محددة
نسبة رضا العملاء عن خدمة معينة عندما يطلب منهم تقييم من واحد الى خمسة

في هذه الامثلة كل قيمة يمكن وضعها في عمود داخل جدول ويمكن للنموذج الرياضي التعامل معها بسهولة في صورة مصفوفات او متجهات لهذا السبب يقال ان البيانات الكمية منظمة بشكل جيد وتناسب مراحل التدريب والاختبار في معظم النماذج

1.12.2 تعريف البيانات النوعية في سياق الذكاء الاصطناعي


البيانات النوعية هي بيانات وصفية تهتم بالاجابة عن اسئلة من نوع ماذا ولماذا وكيف بدلا من كم هي عدديا فهي تركز على الكلمات والمعاني والتجارب الشخصية والعوامل السياقية التي لا يمكن اختزالها مباشرة في رقم واحد

من امثلة البيانات النوعية في التطبيقات

اجابات العملاء عن سؤال مفتوح مثل ما اكثر ما يزعجك في خدمة التوصيل
سجل محادثة بين مريض وطبيب في عيادة نفسية
ملاحظات مراقب ميداني عن سلوك السائقين في شارع مزدحم
رسائل بريدية يرسلها طلاب لادارة جامعة يشرحون فيها مشكلاتهم
تعليقات المستخدمين على تطبيق في متجر التطبيقات

هذه الاجابات تأتي على شكل نصوص طويلة او جمل قصيرة لكنها تحمل معلومات غنية عن الاسباب والمشاعر والتقييمات الضمنية التي لا تظهر في رقم واحد

البيانات في الذكاء الاصطناعي: الكمية مقابل النوعية



1.12.3 طرق جمع البيانات الكمية في المشاريع الواقعية

في المؤسسات والشركات يتم جمع البيانات الكمية عادة من أنظمة معلومات موجودة بالفعل مثل

انظمة نقاط البيع في المتاجر التي تسجل كل عملية شراء بقيمتها وتوقيتها وطريقة الدفع
انظمة الحضور والانصراف التي تسجل وقت دخول وخروج الموظفين
انظمة ادارة التعلم التي تسجل درجات الطلاب في الاختبارات وعدد مرات دخولهم الى المنصة
اجهزة الاستشعار في المصانع التي تقيس درجة الحرارة والضغط وسرعة الانتاج

كذلك تستخدم الاسئلة المغلقة في الاستبيانات كمصدر مهم للبيانات الكمية فعندما يطلب من عميل تقييم تجربته مع خدمة ما من واحد الى عشرة او اختيار نعم او لا حول مسألة محددة فان هذه الاجابات تتحول مباشرة الى قيم رقمية يمكن ربطها بخصائص اخرى مثل المحافظة او العمر او نوع الخدمة

ميزة هذه الطريقة انها تنتج بيانات جاهزة تقريبا للتحليل الاحصائي وللتغذية المباشرة في نماذج التعلم الالي بعد بعض التنظيف البسيط مثل معالجة القيم المفقودة او التحقق من عدم وجود ارقام غير منطقية

1.12.4 طرق جمع البيانات النوعية في المشاريع الواقعية

جمع البيانات النوعية يحتاج الى تواصل مباشر او غير مباشر مع الاشخاص لفهم تجاربهم وله عدة اساليب من بينها

المقابلات الفردية حيث يطرح الباحث اسئلة مفتوحة على شخص واحد مثل صاحب متجر او مريض ويترك له مساحة للشرح والتفصيل


مجموعات النقاش المركزة حيث يجتمع عدد من الاشخاص لمناقشة منتج او فكرة جديدة ويتم تسجيل الحوار وتحليله لاحقا

الاستبيانات التي تحتوي على اسئلة مفتوحة مثل ما اقترحاتك لتحسين هذه الخدمة او اذكر تجربة ايجابية وسلبية مررت بها

الملاحظات الميدانية حيث يقوم الباحث بمراقبة بيئة معينة مثل قاعة درس او موقف حافلات ويكتب ملاحظاته حول السلوكيات المتكررة

جمع تعليقات المستخدمين من شبكات التواصل الاجتماعي او منصات التقييم واعتبارها نصوصا تحليلية

هذه الاساليب تنتج نصوصا ومقاطع صوتية وملاحظات حرة تحتاج لاحقا الى تنظيم وتشفير قبل ادخالها في اي نظام ذكاء اصطناعي



1.12.5 مزايا البيانات الكمية في مشاريع الذكاء الاصطناعي

البيانات **الكمية** مفضلة في كثير من مراحل تطوير النماذج لعدة اسباب

أولاً سهولة التخزين والمعالجة فمن السهل حفظ ملايين السجلات الرقمية في قواعد بيانات ثم تحميلها في برامج تحليل البيانات وتدريب النماذج دون الحاجة الى خطوات معقدة لتحويلها

ثانياً ملائمتها الطبيعية للخوازميات الرياضية فمعظم خوارزميات الانحدار والتصنيف والعنفدة تفترض ان المدخلات اعداد او متغيرات يمكن قياسها مثل العمر والدخل ودرجة الحرارة وعدد مرات الشراء

ثالثاً القدرة على تتبع التغير عبر الزمن بسهولة فعندما تكون البيانات الكمية مسجلة على فترات متتالية يمكن رسم منحنيات لسلوك المبيعات او لمعدل استهلاك الطاقة او لعدد الزيارات اليومية وتحليل الاتجاهات والقمم والهبوط

رابعاً إمكانية استخدام الاساليب الاحصائية التقليدية مثل حساب المتوسطات والانحرافات ومعامل الارتباط لاكتشاف علاقات مبدئية بين المتغيرات قبل حتى الدخول في نماذج معقدة وهذا يساعد فريق البيانات على فهم المشكلة وضبط توقعاته

هذه المزايا تجعل البيانات الكمية حجر اساس في اغلب مشاريع الذكاء الاصطناعي من التنبؤ بالمبيعات الى كشف الاحتيال وتحليل سلوك المستخدمين

1.12.6 حدود البيانات الكمية ومشكلاتها


مع كل قوتها تحمل البيانات الكمية نقاط ضعف اذا اعتمد عليها وحدها دون دعم نوعي

أولاً تميل البيانات الكمية الى الاختزال الشديد فحكم العميل على خدمة معقدة في رقم من خمسة او عشرة لا يوضح السبب الحقيقي وراء هذا الرقم هل هو السعر ام جودة المنتج ام تعامل الموظفين ام سرعة التوصيل هذا النقص في السياق يجعل اتخاذ القرار اعتماداً على الارقام وحدها محدوداً

ثانياً يمكن ان تدخل التحيزات من خلال طريقة صياغة الاسئلة فاذا كان السؤال في الاستبيان موجهاً او يوحى باجابة معينة فسيؤثر توزيع الارقام الناتج دون ان يلاحظ الباحث ذلك مثلاً سؤال من نوع الا توافق على ان الخدمة تحسنت مقارنة بالعام الماضي يحمل افتراضاً مسبقاً بوجود تحسن

ثالثاً الاعتماد على قياسات محددة قد يغفل جوانب اخرى لا تقاس رقمياً بسهولة فقد تكون نسبة الشكاوى قليلة لكن لغة الشكاوى نفسها حادة وتشير الى فقدان ثقة حاد لدى مجموعة صغيرة من العملاء المهمين وهذه الصورة لا تظهر في رقم واحد

رابعاً يمكن ان تؤدي محاولات تحويل كل شيء الى رقم الى اتخاذ قرارات غير انسانية في بعض المجالات الحساسة مثل الصحة والتعليم اذا لم يتم تفسير هذه الارقام في ضوء سياقها الاجتماعي والاخلاقي



1.12.7 مزايا البيانات النوعية في مشاريع الذكاء الاصطناعي

البيانات النوعية تقدم ما تفتقده الارقام وهو العمق والسياق والتفسير

أولاً تسمح بفهم الاسباب الكامنة خلف الظواهر الرقمية فاذا اظهرت البيانات الكمية انخفاضاً في مبيعات فرع معين يمكن لتحليل تعليقات الزبائن في ذلك الفرع ان يكشف ان المشكلة ليست في المنتج بل في التعامل او في نظافة المكان او في موقعه

ثانياً تظهر في البيانات النوعية **المشاعر والانطباعات** التي لا يمكن قياسها مباشرة مثل شعور الامان في مرفق صحي او احساس الطالب بان المعلم يهتم به او شعور المستخدم بان واجهة التطبيق معقدة او مرهقة

ثالثاً تساعد **على اكتشاف عوامل جديدة** لم تكن في الحسبان عند تصميم نموذج الذكاء الاصطناعي في البداية فمثلا قد يكتشف فريق البيانات من خلال قراءة تعليقات المرضى ان الوقت الذي ينتظرونه في موقف السيارات قبل دخول العيادة يؤثر في تقييمهم للتجربة رغم ان هذا المتغير لم يكن مسجلا في النظام من قبل

رابعا تساعد البيانات النوعية في تفسير نتائج **النموذج بعد تدريبه** فبدلا من الاكتفاء بمعرفة ان احتمال الغاء اشتراك عميل معين مرتفع يمكن الرجوع الى نصوص تفاعلاته السابقة او شكاواه لمعرفة ما الذي يدفعه للتفكير في الانسحاب ومن ثم اقتراح حل مناسب

1.12.8 تحديات التعامل مع البيانات النوعية تقنيا وتنظيما

رغم فوائدها الكبيرة الا ان البيانات النوعية **ليست سهلة الاستخدام** في مشاريع الذكاء الاصطناعي

اولاً تحتاج الى **خطوات تجهيز معقدة** فالنصوص الحرة يجب تنظيفها من الرموز الزائدة وتقسيمها الى كلمات وتحويلها الى تمثيل رقمي باستخدام تقنيات معالجة اللغة الطبيعية مثل التمثيلات العددية للكلمات ثم استخدام نماذج متخصصة مثل نماذج التصنيف النصي لاستخراج المعاني الرئيسية

ثانياً تفسير نتائج **التحليل النوعي** يتطلب فهما عميقا لمجال المشكلة فقراءة تعليقات المرضى تحتاج الى شخص لديه معرفة طبية اساسية ليفرق بين وصف عرض عابر ووصف مشكلة خطيرة وكذلك تحليل تعليقات المستثمرين يحتاج الى فهم مالي واقتصادي حتى لا يساء تفسير المخاوف او التوقعات

ثالثاً البيانات **النوعية اكثر حساسية** من حيث الخصوصية لانها تحتوي غالبا على تفاصيل شخصية او عبارات يمكن ان تكشف عن هوية الاشخاص او مشكلاتهم بشكل مباشر وبالتالي تحتاج الى عناية اكبر في اخفاء الهوية وتطبيق القواعد القانونية والاخلاقية

رابعا الكمية الكبيرة من النصوص قد تجعل عملية **التحليل اليدوي مرهقة** لهذا تأتي الحاجة الى نماذج متقدمة للذكاء الاصطناعي تتعامل مع **اللغة الطبيعية لكنها بدورها تحتاج** الى بيانات تدريبية كبيرة ونظيفة ومصنفة مسبقا

1.12.9 مقارنة تفصيلية بين النوعين من حيث الاستخدام في الذكاء الاصطناعي

من حيث الهدف العام تستخدم البيانات الكمية عندما يكون الهدف الرئيسي هو **التنبؤ بقيمة رقمية** او **اتخاذ قرار واضح** مثل قبول او رفض او تصنيف حالة الى فئة محددة بينما تستخدم البيانات النوعية عندما نريد فهم **الاسباب** وتحليل التجربة وتحديد العوامل المؤثرة غير الظاهرة

من حيث تكلفة الجمع تكون البيانات الكمية في كثير من الاحيان **متاحة اصلا** داخل الانظمة التشغيلية ولا تحتاج الا الى استخراج وتنظيف اما البيانات النوعية فتحتاج الى تصميم **اسئلة مفتوحة** واجراء مقابلات او جمع تعليقات وهو ما يتطلب وقتا اطول وتنظيما ادق

من حيث المهارات المطلوبة يستطيع مهندس البيانات التعامل مع البيانات الكمية بالاعتماد على مهارات **الرياضيات والبرمجة والتحليل الإحصائي** بينما تحتاج البيانات النوعية الى مشاركة باحثين اجتماعيين او خبراء مجال لفهم اللغة والسياق وتقديم تفسير سليم للنتائج

من حيث المخاطر تميل البيانات الكمية الى اخفاء التحيز خلف ارقام تبدو علمية لكنها قد تمثل جزءا غير متوازن من المجتمع اما البيانات النوعية فخطرها الاكبر هو التفسير الشخصي الزائد اذا لم يتم تنظيمها وتحليلها بطريقة منهجية واضحة


1.12.10 الدمج بين البيانات النوعية والكمية في دورة مشروع الذكاء الاصطناعي

اقوى مشاريع الذكاء الاصطناعي هي تلك التي تدمج بين النوعين في مراحل مختلفة من دورة حياة المشروع في مرحلة فهم المشكلة يمكن الاستفادة من البيانات النوعية عبر مقابلات مع اصحاب المصلحة وسماع قصص المستخدمين لاستخلاص الفرضيات الاولى حول العوامل المهمة ثم تستخدم البيانات الكمية للتحقق من هذه الفرضيات وقياس حجم تأثير كل عامل

في مرحلة تصميم الاستبيان من المفيد استخدام اسئلة مفتوحة في البداية لجمع انطباعات حرة ثم تحويل اهم ما يظهر فيها الى اسئلة مغلقة يمكن قياسها رقميا في استبيان اوسع لنطاق اكبر من الناس

في مرحلة التدريب يمكن ان يعتمد النموذج الاساسي على بيانات كمية مثل عدد الزيارات ومدة الاستخدام والتقييم الرقمي ثم يستخدم نموذج نصي مساعد لتحليل تعليقات المستخدمين وتصنيفها الى محاور مثل السعر والجودة والدعم الفني بحيث يمكن ربط كل محور بالتغير في التقييمات الرقمية

في مرحلة تفسير النتائج والتحسين المستمر تساعد البيانات النوعية على فهم لماذا اخطأ النموذج في حالات معينة ولماذا تغير سلوك المستخدمين في فترة ما بالرغم من استقرار المؤشرات الرقمية الاخرى



مثال تطبيقي مبسط

تخيل منصة تعليم رقمي في الاردن تريد بناء نموذج يتنبأ بخطر انسحاب الطالب من دورة معينة البيانات الكمية المتاحة تشمل عدد مرات دخول الطالب للدروس مدة بقائه في كل جلسة درجاته في الاختبارات القصيرة وتاريخ تسجيله اما البيانات النوعية فتشمل اجابات الطلبة في سؤال مفتوح في نهاية الدورة عن الصعوبات التي واجهوها وتعليقاتهم في منتدى النقاش

يمكن للنموذج في مرحلته الاولى ان يعتمد على البيانات الكمية لتحديد انماط عامة مثل ان الطلاب الذين يقل عدد دخولهم عن حد معين او يتدنى ادائهم في ثلاثة اختبارات متتالية معرضون اكثر للانسحاب لكن لفهم السبب الحقيقي يمكن تحليل النصوص النوعية فيجد الفريق ان السبب الاكثر تكرارا هو سرعة الانترنت في بعض المناطق او صعوبة اللغة المستخدمة او عدم توفر شرح كاف للتمارين

بهذا الدمج يصبح قرار الادارة اكثر ذكاء ليس فقط بتمييز من هو معرض للانسحاب بل بمعرفة ما الذي يجب تعديله لتحسين التجربة مثل تبسيط لغة المحتوى او توفير نسخ خفيفة من الفيديو تناسب سرعات الانترنت المحدودة او زيادة الدعم التفاعلي في اوقات معينة

خاتمة

المقارنة بين البيانات النوعية والبيانات الكمية في مشاريع الذكاء الاصطناعي ليست مجرد تفصيل نظري بل هي جزء اساسي من وعي الطالب والمهني على حد سواء بطبيعة ما يتعامل معه فالبيانات الكمية تمنح النموذج قوة حسابية وقدرة على التنبؤ على نطاق واسع لكنها تحتاج دائما الى تفسير انساني مدعوم ببيانات نوعية تكشف الاسباب والدوافع والظروف المحيطة والبيانات النوعية تمنح المشروع عمقا وفهما حقيقيا لتجربة الناس لكنها تحتاج الى تنظيم وتحويل ذكي حتى تصبح قابلة للاستفادة في النماذج

المشروعات التي تبني قراراتها على نوع واحد فقط تخاطر بان تقدم صورة ناقصة اما المشاريع التي تجمع بين الارقام والكلمات بين القياس والتفسير فتصبح اقرب الى الواقع واعمق فهما له وهذا بالضبط ما يحتاجه سوق العمل اليوم من مختصي البيانات والذكاء الاصطناعي الذين لا يرون في البيانات مجرد جداول جامدة بل انعكاسا متكاملًا لحياة الناس وسلوكهم واختياراتهم

فيديوهات شرح :

<https://www.youtube.com/watch?v=JgJwRwNvs8I>

<https://www.youtube.com/watch?v=Xvx-nlHWCMA>

https://www.youtube.com/watch?v=ZyM5ArzQC_s

<https://www.youtube.com/watch?v=dybUICgnejE>

1.13 أنشطة معالجة البيانات واستخدامها في حلول الذكاء الاصطناعي



1.13.1 التحليلات الوصفية

يقصد بالتحليلات الوصفية تحليل **البيانات التاريخية** لفهم ما حدث في الماضي دون محاولة التنبؤ بالمستقبل بشكل مباشر فهي تجيب عن أسئلة مثل ماذا حدث واين ومتى ومع من في شركة تجزئة مثلا يمكن لنظام ذكاء اصطناعي ان يحلل مبيعات الاشهر الاثني عشر الماضية ليحدد اكثر المنتجات راجا في كل فرع واكثر الايام ازدهارا وافضل الفترات الزمنية للعروض الترويجية كما يستطيع اكتشاف انماط مثل ارتباط شراء سلعة معينة مع سلعة اخرى هذا النوع من التحليل يوفر صورة واضحة عن سلوك العملاء ويساعد في تجهيز **بيانات نظيفة وغنية** تستخدم لاحقا في تدريب نماذج تعلم آلي اكثر تقدما


1.13.2 التحليلات التشخيصية

تذهب التحليلات التشخيصية خطوة أبعد من الوصف فهي لا تكتفي بسرد ما حدث بل تحاول الإجابة عن سؤال لماذا حدث ذلك وبهذا تركز على العلاقات السببية والعوامل التي تقف خلف الظاهرة تخيل شركة تدير اسطولا من حافلات النقل العام تقوم بتزويد الحافلات بحساسات تقيس ضغط الاطارات وحرارة المحرك والسرعة ونمط الكبح ثم يستخدم نظام ذكاء اصطناعي هذه القراءات ليربط بين حالات العطل السابقة وبين قيم الحساسات قبل العطل فيتعرف على الانماط التي تسبق المشكلات الميكانيكية وبذلك يمكنه تفسير سبب زيادة الاعطال في نوع معين من الحافلات او في خط سير محدد هذه الرؤية التشخيصية تسمح للشركة باتخاذ اجراءات وقائية مثل تغيير قطع معينة في وقت مبكر او تعديل اسلوب القيادة قبل ان تتحول المشكلة الى توقف مفاجئ مكلف

1.13.3 عمليات الاستخراج والتحويل والتحميل ETL و ELT

كثيرا ما تكون بيانات المؤسسة موزعة بين قواعد بيانات مختلفة وملفات اكسل وواجهات برمجة تطبيقات خارجية وهنا تأتي عملية الاستخراج والتحويل والتحميل المعروفة اختصارا بـ ETL حيث يتم اولا استخراج البيانات من مصادر متعددة ثم تحويلها الى تنسيق موحد من حيث صيغ التواريخ وانواع الحقول ووحدات القياس واسماء الاعمدة واخيرا تحميلها في مستودع بيانات مركزي يمكن لفرق التحليل ونماذج الذكاء الاصطناعي الوصول اليه ومع انتشار التخزين السحابي ظهرت طريقة معكوسة تسمى ELT بحيث يتم استخراج البيانات وتحميلها اولا الى السحابة ثم تنفيذ التحويلات عليها هناك مستفيدة من قدرة المنصات السحابية على المعالجة السريعة لكميات ضخمة من البيانات في الحالتين الهدف هو تجهيز بيانات متسقة ونظيفة وقابلة للمشاركة بين الانظمة المختلفة

مفاهيم تحليل البيانات: وصفية، تشخيصية، ومعالجة



1.13.4 التحليلات التنبؤية

تعتمد التحليلات التنبؤية على **النماذج الاحصائية وخوارزميات التعلم الآلي** لاستشراف ما قد يحدث في المستقبل بالاعتماد على بيانات الماضي والحاضر مثلاً في شركة تأمين يمكن تدريب نموذج على بيانات العملاء السابقين التي تشمل العمر ونوع المركبة وسجل الحوادث وطبيعة المنطقة الجغرافية ليقدّر مستوى الخطر لكل عميل جديد ومن ثم اقتراح قسط تأمين عادل يوازن بين احتمال وقوع المطالبات وبين تكلفة تشغيل الشركة ومثل ذلك يمكن لمتجر الكتروني ان يستخدم التحليلات التنبؤية لتقدير الطلب المتوقع على منتج معين في شهر قادم فيرفع المخزون قبل الموسم بدلا من الانتظار حتى تظهر المشكلة


1.13.5 التحليلات التوصيفية او الاجرائية

التحليلات التوصيفية وهي التي يشار اليها احيانا **بالتحليلات الاجرائية او الوصفية المستقبلية** تهدف الى **اقتراح افضل الاجراءات الممكنة** وليس فقط وصف الماضي او التنبؤ بالمستقبل فهي تربط نتائج النماذج التنبؤية بمجموعة من البدائل لتجيب عن سؤال ماذا ينبغي ان نفعل الان مثلاً في سلسلة محلات كبرى يمكن لنظام ذكاء اصطناعي ان يحلل بيانات المخزون ومبيعات كل فرع وازمنة الشحن وتوقعات الطلب المستقبلية ثم يقترح بشكل آلي الكميات التي يجب ارسالها من مركز التوزيع الى كل فرع كما يقترح متى يجب اعادة الطلب من الموردين واي المنتجات يمكن نقلها من فرع الى اخر لتقليل الهدر وهذه التوصيات **تساعد الإدارة** على تحقيق توازن بين توافر البضاعة وتقليل المخزون الزائد وزيادة الربحية

1.13.6 تمثيل البيانات بصريا

حتى تكون نتائج الذكاء الاصطناعي مفهومة ومفيدة لصانع القرار لا يكفي عرضها في جداول رقمية معقدة بل يحتاج الامر الى **تمثيل بصري** واضح للبيانات والمخرجات من خلال **الرسوم البيانية والمخططات والخرائط الحرارية وغيرها** فعلى سبيل المثال يمكن عرض تطور مبيعات منتج معين على شكل منحنى زمني يظهر القمم والهبوط او استخدام مخطط اعمدة لمقارنة فروع مختلفة او خريطة تبين المناطق التي يزداد فيها الطلب على خدمة ما هذه التمثيلات البصرية تساعد على اكتشاف الانماط بسرعة وفهم العلاقة بين المتغيرات وتجعل من السهل على غير المتخصصين في علم البيانات استيعاب ما توصلت اليه النماذج الذكية وتحويله الى قرارات عملية في الوقت المناسب

مفاهيم متقدمة في تحليل البيانات: التنبؤ، التوصيف، والتمثيل البصري



1.14 جمع بيانات مشاريع الذكاء الاصطناعي وتجهيزها واختيار المصادر المناسبة

بدأ أي مشروع ذكاء اصطناعي ناجح من نقطة واحدة أساسية هي **البيانات** لذلك يركز هذا الجزء على كيف نجمع البيانات ونجهزها قبل استخدامها في النماذج الذكية فالبيانات في الواقع غالباً لا تأتي في شكل منظم وجاهز بل تكون ناقصة أو غير مرتبة أو مخلوطة بأنواع أخرى من المعلومات وهذا يفرض عملاً إضافياً لتجهيزها كما يفرض الانتباه للجوانب الأخلاقية والقانونية والأمنية المرتبطة بحماية خصوصية الأشخاص والالتزام بقوانين حماية البيانات في البلد

1.14.1 أولاً مبادئ جمع البيانات وتجهيزها لمشاريع الذكاء الاصطناعي

أحد الأسباب الرئيسية لفشل مشاريع الذكاء الاصطناعي هو اختيار بيانات غير مناسبة أو تجميعها بطريقة خاطئة لذلك هناك مجموعة مبادئ عامة يجب الالتزام بها عند العمل على أي مشروع

المبدأ الأول فهم المتطلبات بشكل كامل

قبل جمع أي نوع من البيانات **يجب أن يكون هدف المشروع واضحاً** ما السؤال الذي نريد من النظام الإجابة عنه وما القرار الذي سيساعدنا على اتخاذه بناء على ذلك نحدد نوع البيانات المطلوبة هل نحتاج بيانات رقمية أم نصية أم صوراً أم قياسات حساسات وما الشكل الذي نريد تخزينها به كما نقرر معدل تكرار جمعها هل نحتاج بيانات كل ساعة أم يومياً أم شهرياً مثلاً في مشروع يتنبأ باستهلاك الكهرباء قد

نحتاج قراءات كل ساعة اما في مشروع يتنبأ بمبيعات شهرية فيكفي جمع بيانات على مستوى الايام او الاسابيع

المبدأ الثاني التأكد من دقة البيانات ونزاهتها

لا يكفي ان تتوافر البيانات بل يجب ان تكون موثوقة ومن مصدر قانوني وأمن لذلك من المهم التأكد من ان الجهة التي تزودنا بالبيانات مرخصة وان طريقة جمع البيانات لا تخالف القوانين في بعض الحالات يتم توقيع عقد بيانات بين الاطراف يحدد المسؤوليات وحقوق الاستخدام وبعد ضمان شرعية المصدر ننقل الى فحص جودة البيانات نفسها كالبحت عن سجلات مكررة وقيم مفقودة وتناقض بين الحقول مثل وجود تاريخ لاحق لتاريخ التسجيل او قيم غير منطقية للسن او الراتب معالجة هذه المشكلات مبكرا تحمي النموذج من تعلم انماط خاطئة

المبدأ الثالث الحد من التحيز وضمان تنوع البيانات

لكي تكون نتائج الذكاء الاصطناعي عادلة قدر الامكان يجب ان تمثل البيانات اشخاصا ومناطق وظروفا مختلفة لا فئة واحدة فقط فمثلا اذا كنا نبني نمودجا لتحليل طلبات قروض فمن غير المقبول ان تكون معظم البيانات من فئة عمرية واحدة او من منطقة واحدة لان النموذج حينها سيتعلم انماطا منحازة الى تلك الفئة لذلك يجب الانتباه الى التنوع الديموغرافي والجغرافي وطريقة جمع العينات والتأكد من انها تعكس الواقع الذي نريد ان يعمم عليه النموذج قدر الامكان


المبدأ الرابع تنظيف البيانات وتجهيزها فنيا

بعد جمع البيانات تبدأ مرحلة التطهير بحيث نعالج القيم المفقودة اما بتقديرها او استبعادها حسب الحالة ونفحص القيم الشاذة التي تبدو بعيدة جدا عن باقي البيانات ونتأكد هل هي اخطاء تسجيل ام حالات حقيقية كما نحذف البيانات العشوائية غير الضرورية التي لا علاقة لها بالمشكلة لان وجودها قد يربك النموذج ويجعله يتعلم ضوضاء بدلا من الانماط المهمة بعد ذلك نطبق تحويلات مناسبة مثل توحيد صيغ التواريخ تحويل الوحدات الرياضية ترميز القيم الفئوية الى ارقام تجهيز النصوص لتعمل مع خوارزميات معالجة اللغة الطبيعية وهكذا تصبح مجموعة البيانات جاهزة للدخول في نماذج التعلم الالي

المبدأ الخامس احترام الاخلاقيات والقوانين دائما

اي مشروع يتعامل مع بيانات اشخاص حقيقيين يجب ان يضع الخصوصية في المقدمة لذلك من الضروري اخفاء معلومات التعريف الشخصية مثل الاسم الكامل والرقم الوطني ورقم الهاتف والعنوان الدقيق قدر الامكان عن طريق استبدالها بمعرفات مجهولة لا تربط مباشرة بالهوية الحقيقية كما يجب الالتزام بقوانين حماية البيانات المحلية والاقليمية التي تحدد ما يجوز جمعه وكيفية تخزينه ومدة الاحتفاظ به ومن يحق له الوصول اليه فالذكاء الاصطناعي الناجح لا يقوم فقط على دقة التنبؤ بل ايضا على احترام حقوق الافراد

مبادئ جمع البيانات وتجهيزها لمشاريع الذكاء الاصطناعي



1.14.2 اختيار البيانات ومصادرها المناسبة لمشروع الذكاء الاصطناعي

في أغلب الاحوال يكون نظام الذكاء الاصطناعي جزءا من سلسلة عمل كاملة يستقبل بيانات في البداية ثم ينتج مخرجات تساعد المستخدم النهائي على اتخاذ قرار ولذلك يجب التفكير بعناية في نوعية البيانات ومصادرها

الخطوة الاولى تحديد هدف المشروع او المهمة

فهم هدف المشروع يساعد مباشرة في تحديد نوع البيانات المطلوبة فالنموذج الذي ينتبأ بحالة الطقس يحتاج الى سجلات تاريخية لدرجات الحرارة والضغط والرطوبة وسرعة الرياح بينما النموذج الذي يقدر احتمال حدوث سرقة في حي معين يحتاج الى بيانات اخرى مثل سجلات حوادث الشرطة ومطالبات التأمين والخصائص العامة للمنطقة مثل نوع المباني وكثافة السكان كل هدف مختلف يقود الى مصادر مختلفة للبيانات

الخطوة الثانية مراجعة البيانات المتاحة داخل المؤسسة

قبل البحث عن بيانات خارجية مكلفة من المفيد فحص ما هو متوفر اصلا داخل الانظمة الحالية فقد تكون المؤسسة تخزن منذ سنوات سجلات المبيعات او بيانات الزبائن او قراءات الحساسات للاستخدامات اليومية دون ان تفكر في استغلالها في مشروع ذكاء اصطناعي هذه البيانات قد لا تكون مرتبة تماما لكنها نقطة انطلاق ممتازة توفر الوقت والمال مقارنة بالبداية من الصفر

الخطوة الثالثة تقييم سلامة وملاءمة البيانات المتاحة


اذا لم تتوفر بيانات مناسبة داخليا او كانت ناقصة يجب البحث عن مصادر بديلة قد تكون جهات

حكومية او شركات متخصصة او حتى تركيب حساسات جديدة لجمع بيانات خاصة بالمشروع مثل شركة زراعية تقوم بوضع حساسات رطوبة وحرارة في بيوت بلاستيكية للحصول على سلسلة زمنية دقيقة قبل شراء اي بيانات او تركيب اي نظام يجب طرح مجموعة من الاسئلة هل الوصول الى البيانات سهل ام يتطلب اجراءات معقدة هل المصدر موثوق وهل الدقة مقبولة وهل حجم البيانات يكفي لتقسيمها الى مجموعة تدريب واختبار وهل هي حديثة وتعكس الوضع الحالي وهل تحتوي على تنوع مناسب يمنع التحيز وهل توجد قيود قانونية او اخلاقية تمنع استخدامها وهل يمكن توفير تدفق مستمر من البيانات مستقبلا اذا كان النموذج يحتاج الى اعادة تدريب

الخطوة الرابعة كشف اوجه القصور بالاختبار التجريبي

من الممارسات الجيدة تنفيذ تجربة صغيرة على جزء من البيانات قبل الاستثمار الكبير في شراء تراخيص او بناء بنية تحتية كاملة في هذا الاختبار يتم تدريب نموذج اولي بسيط وقياس دقته وادائه اذا كانت النتائج ضعيفة قد يكون السبب في نقص نوع معين من البيانات او وجود تحيزات او اخطاء في التسجيل كما يمكن في هذه المرحلة استشارة خبراء المجال وعلماء البيانات الاخرين للحصول على تقييم مستقل قبل اتخاذ القرار النهائي باستمرار المشروع او تعديل تصميمه

ثانياً: اختيار البيانات ومصادرها المناسبة لمشروع الذكاء الاصطناعي



1.14.3 جمع البيانات وتجهيزها بشكل عملي للمشروع

بعد اختيار المصادر والتأكد من صلاحية البيانات يبدأ العمل العملي على جمعها وتوحيدها وتخزينها في هيكل يناسب النماذج المستهدفة يجب الانتباه الى ان سوء تجهيز البيانات قد يؤدي الى مشكلات عديدة مثل طول زمن التدريب مع نتائج ضعيفة او نماذج تنحاز لفئات معينة او توقعات لا تنطبق على الواقع لذلك تعد مرحلة الجمع والتجهيز عملاً استثمارياً حقيقياً في نجاح المشروع فكل دقيقة تبذل في تنظيم البيانات وتنظيفها وفهم حدودها توفر الكثير من الوقت والمال عند تشغيل نظام الذكاء الاصطناعي في بيئة العمل الفعلية

بهذا الفهم يصبح الطالب قادرا على رؤية ان جمع البيانات وتجهيزها ليس عملا تقنيا ثانويا بل هو اساس نجاح مشاريع الذكاء الاصطناعي من حيث الدقة والعدالة والالتزام بالقانون والاخلاق.

ما هو التحيز في البيانات؟

. الفكرة الأساسية:

- البيانات تبدو في البداية محايدة، كأنها أرقام وجداول بلا رأي.
- في مشروعات الذكاء الاصطناعي قد تحمل هذه الجداول تحيزًا خفيًا.

. تعريف التحيز في هذا السياق:

- ظهور فئة معينة من الأشخاص أو الحالات في البيانات أكثر من غيرها.
- أو معاملة مختلفة لفئة معينة أثناء جمع البيانات أو معالجتها.
- النتيجة: النموذج يتعلم صورة منحرفة عن الواقع تميل نحو فئة وتُهمل أخرى.

كيف يبدأ التحيز من جمع البيانات؟

. أمثلة عملية:

- مستشفى يجمع بيانات مرضى من منطقة واحدة لسنوات:
- النموذج يتعلم نمط المرض في تلك المنطقة فقط.
- عند استخدامه في مدينة أخرى يخطئ كثيرًا.
- شركة تجمع بيانات عملائها من تطبيق الهاتف فقط:
- الفئات التي لا تستخدم التطبيق تصبح ممثلة تمثيلاً ضعيفًا.
- رغم أنها قد تكون جزءًا كبيرًا من السوق الحقيقي.

. الفكرة العامة:

- الاعتماد على مصدر واحد أو قناة واحدة يؤدي إلى صورة ناقصة عن الواقع.



1.15 مشكلات التحيز غير المرئي في مخرجات الذكاء الاصطناعي

. المشكلة الأولى: دقة تحليل غير حقيقية

- النموذج لا يرى الصورة الكاملة بل جزءًا منها ويظنه الكل.
- مثال: نظام يتنبأ بتسرب الطلبة من التعليم:
- إذا تدرب على مدرسة خاصة واحدة، سيظن أن أسباب التسرب هي ما يراه هناك فقط.
- بينما قد تكون أسباب التسرب في المدارس الحكومية مختلفة تمامًا.

. المشكلة الثانية: انخفاض دقة النموذج على بيانات جديدة

- عند تجربة النموذج على بيئة أو منطقة مختلفة:
- يعطي قرارات متقلبة وغير موثوقة.
- لا يمكن الاعتماد عليه في اتخاذ قرارات مهمة.

. المشكلة الثالثة: ظلم بعض الفئات

- أمثلة على القرارات المجحفة:
- رفض طلبات قروض لفئة اجتماعية معينة بشكل متكرر.
- تقليل فرص قبول متقدمين لوظائف من مناطق محددة.
- تجاهل مؤشرات مرض عند مجموعة من المرضى.
- النتيجة الأخطر: ضعف ثقة الناس في أنظمة الذكاء الاصطناعي.

1.15.1 نوع التحيز الأول: التحيز غير المقصود

. خصائصه:

- هو الأكثر انتشارًا في التطبيقات الواقعية.

- يحدث عندما تصمم تجربة جمع البيانات أو اختيار العينة بشكل يبدو منطقيًا لكنه يستبعد جزءًا مهمًا من الواقع دون قصد.

• أمثلة:

- شركة تريد أتمتة فرز طلبات التوظيف:
 - تستخدم بيانات الموظفين الناجحين في الماضي لتدريب النموذج.
 - إذا كانت الشركة تاريخيًا توظف أكثر من فئة عمرية أو مدينة معينة:
 - سيتعلم النموذج أن هذه الفئة هي الأفضل.
 - مرشحون أكفأ من فئات أخرى قد لا يحصلون على فرصة؛ لأن بياناتهم قليلة.
- نموذج طبي لتشخيص مرض جلدي:
 - يتدرب على صور مرضى ذوي بشرة فاتحة فقط.
 - عند استخدامه مع مرضى ذوي بشرة داكنة ينخفض الأداء؛ لأن البيانات لا تمثل جميع أنواع البشرة.

1.15.2 نوع التحيز الثاني: التحيز الخوارزمي

• ما المقصود به؟

- تحيز ناتج عن تصميم النموذج نفسه أو طريقة معالجته للبيانات.
- ليس مرتبطًا فقط بعيوب في البيانات، بل في اختيار الخوارزمية وتحويل المتغيرات.

• كيف يحدث؟

- لكل خوارزمية طريقة في التركيز على أنماط معينة وإهمال أخرى.
- اختيار خوارزمية غير مناسبة لطبيعة المشكلة أو تحويل المتغيرات بشكل غير مدروس:

- قد يضخم تأثير بعض العوامل على حساب عوامل أخرى.
- بدون أن ينتبه أحد داخل الفريق.

• مثال عملي:

- تحليل بيانات قروض:
 - تحويل "مهنة العميل" إلى رقم بطريقة تجعل بعض الأعمال تملك قيمة أكبر.
 - يبدأ النموذج في اعتبار هذه المهنة عاملاً حاسماً.
 - رغم أن الواقع قد لا يعطي هذه المهنة كل هذا الوزن.
- الصعوبة:
 - مخرجات النموذج تبدو منطقية من النظرة الأولى.
 - لكن عند فحص النتائج لكل فئة يظهر أن النموذج أكثر إنصافاً لفئة وأقل لفئة أخرى.

1.15.3 نوع التحيز الثالث: التحيز النظامي أو المؤسسي

• عمق المشكلة:

- ليس مجرد خطأ تقني في البيانات أو الخوارزمية.

• مرتبط بثقافة المؤسسة وسياساتها ونظرتها للفئات المختلفة.

كيف يظهر؟

- إذا كانت رؤية المؤسسة غير متوازنة وتعطي أفضلية واضحة:
 - لفئة من العملاء.
 - أو نوع معين من الموظفين.
 - أو مناطق جغرافية محددة.
- فستنعكس هذه الرؤية في كل مراحل مشروع الذكاء الاصطناعي:
 - صياغة سؤال المشروع: ما الهدف؟
 - تحديد ما نعتبره "نجاحاً" للنموذج.
 - اختيار المتغيرات التي ندخلها في التحليل.

النتيجة:


- لا يكفي تعديل بيانات التدريب أو تغيير الخوارزمية.
- يجب مراجعة طريقة اتخاذ القرار داخل المؤسسة حتى لا يتحول الذكاء الاصطناعي إلى أداة تعيد إنتاج التمييز القديم بشكل آلي وسريع.

مشكلات وأنواع التحيز في الذكاء الاصطناعي

3. مشكلات التحيز غير المرئي في المخبرات



أنواع التحيز




1.15.4 التحيز المقصود (الإيجابي أو المفيد)

ليس كل تحيز سيئاً دائماً:

- في بعض الحالات يتم إدخال تحيز مقصود وواضح لتحقيق هدف مقبول.
- أمثلة:
 - أنظمة التوصية في المنصات الترفيهية والمتاجر الرقمية:
 - التركيز على سلوك مستخدمين مشابهين للمستخدم الحالي.
 - "من شاهد هذا الفيلم أعجبه أيضاً..."

- هنا التحيز موجه لخدمة المستخدم ومساعدته على العثور على محتوى يناسب ذوقه.
- أنظمة مساعدة القيادة في السيارات الذكية:
- تدريب الخوارزمية لتكون شديدة الحذر في مواقف معينة:
- التجاوز في طريق ضيق.
- الاقتراب من المشاة.
- التحيز هنا لصالح السلامة والاحتياط.
- الفرق المهم:
- هذا النوع من التحيز:
- مقصود، واضح، ومكتوب في مواصفات النظام.
- ليس مخفياً داخل البيانات أو الخوارزمية.

✓ التحيز المقصود (الإيجابي أو المفيد)



الفرق المهم: الوضوح والقصد



1.15.5 أين المشكلة الحقيقية في التحيز؟

• جوهر المشكلة:

- المشكلة ليست في وجود التحيز بحد ذاته.
- المشكلة في وجود تحيز غير مرئي وغير معترف به:
- خاصة في بيانات التدريب.
- وفي المراحل الأولى من تصميم المشروع.


• خطورة هذا التحيز:

- يبنى عليه نموذج يتخذ قرارات تمس حياة الناس اليومية:
- قبول الطلاب.
- توزيع الموارد.
- منح القروض.
- اتخاذ قرارات طبية.

• مسؤولية فريق العمل:

- مسؤولية أخلاقية وعلمية:
- البحث عن أنواع التحيز.
- تحليل أسبابها.
- الإفصاح عنها.
- التقليل من أثرها قدر الإمكان.

أين المشكلة الحقيقية في التحيز؟



1.15.6 خطوات عملية للحد من التحيز في البيانات والنماذج

الخطوة الأولى: تنوع مصادر البيانات والعينات

- تجنب الاعتماد على مصدر واحد ضيق:
- جغرافيًا (منطقة واحدة).
- أو اجتماعيًا (فئة واحدة).
- جمع بيانات من:
- أكثر من منطقة.
- أكثر من فترة زمنية.
- شرائح سكانية مختلفة.
- الهدف: أن يعكس التدريب تنوع الواقع الحقيقي.

الخطوة الثانية: فحص وتحليل البيانات قبل التدريب

- تحليل توزيع كل متغير.
- رسم العلاقات بين المتغيرات.
- البحث عن إشارات التمثيل الناقص للفئات:
- مثل قلة أمثلة النساء مقارنة بالرجال في بيانات التوظيف.
- أو غياب فئة عمرية كاملة من مجموعة التدريب.

الخطوة الثالثة: قياس العدالة وليس الدقة فقط


- عدم الاكتفاء بنسبة دقة عامة.
- مقارنة أداء النموذج على مجموعات فرعية مختلفة:

- ذكور / إناث.
- مناطق مختلفة.
- فئات عمرية متعددة.
- السؤال المهم:
- هل يخطئ النموذج مع مجموعة أكثر من أخرى؟

الخطوة الرابعة: مراجعة القرارات من فريق متنوع

- مراجعة دورية للقرارات الصادرة عن النموذج.
- إشراك مختصين غير تقنيين:
- أطباء في المشاريع الطبية.
- معلمين في المشاريع التعليمية.
- قانونيين في أنظمة القروض والتمويل.
- هذه النظرة المتعددة الزوايا تكشف مشكلات لا يلاحظها فريق تقني واحد.

خطوات عملية للحد من التحيز في البيانات والنماذج



1.15.7 النتيجة النهائية: نحو أنظمة أكثر عدلاً وشفافية

- عندما تتعامل المؤسسات بجدية مع موضوع التحيز:
- وتعتبره جزءاً أساسياً من تصميم المشروع منذ البداية.
- يصبح من الممكن:
- بناء أنظمة ذكاء اصطناعي أكثر عدلاً وشفافية.
- احترام الاختلاف بين الناس وعدم إعادة إنتاج الصور النمطية القديمة.
- الحفاظ على ثقة المستخدمين والمجتمع في التقنيات الذكية.
- خاصة مع توسع استخدام الذكاء الاصطناعي في:
- الصحة.
- التعليم.
- المال.
- النقل.
- الترفيه.

فيديو يشرح التحيز في الذكاء الاصطناعي : التحيز

ثالثاً: جدول لأنواع التحيز وأمثلة لكل نوع

نوع التحيز	أين يظهر؟	مثال من النص	تأثيره على النموذج	ماذا نحتاج لمعالجته؟
التحيز في جمع البيانات	مرحلة جمع البيانات وبناء العينة	مستشفى يجمع بيانات من منطقة واحدة فقط، أو شركة تعتمد على تطبيق الهاتف فقط	النموذج لا يرى إلا جزءاً من الواقع	تنويع مصادر البيانات والعينات جغرافياً واجتماعياً
التحيز غير المقصود	تصميم التجربة واختيار العينة	توظيف يعتمد على بيانات موظفين ناجحين من فئة معينة تاريخياً	ترجيح فئة عمرية/منطقة على أخرى دون سبب حقيقي	مراجعة تصميم التجربة وفحص تمثيل كل الفئات في البيانات
التحيز الخوارزمي	تصميم النموذج وتحويل المتغيرات	تحويل "مهنة العميل" إلى رقم يعطي وزناً عالياً لمهن معينة	تضخيم أثر بعض العوامل وإضعاف أخرى	اختيار خوارزميات مناسبة وتحويل منظم ومدرّس للمتغيرات
التحيز النظامي/المؤسسي	ثقافة المؤسسة وسياساتها	رؤية داخلية تعطي أفضلية واضحة لفئة من العملاء أو الموظفين	انعكاس التمييز المؤسسي داخل قرارات النموذج	مراجعة سياسات المؤسسة وتعريف "النجاح" ومعايير التقييم
التحيز المقصود (الإيجابي)	تصميم النظام لتحقيق هدف واضح	أنظمة التوصية أو أنظمة مساعدة القيادة الحذرة	تحسين تجربة المستخدم أو رفع مستوى السلامة	أن يكون هذا التحيز معلناً ومفهوماً ومكتوباً في مواصفات النظام

رابعاً: جدول مختصر لخطوات الحد من التحيز

الخطوة العملية	الهدف منها	ملاحظة مهمة
تنويع مصادر البيانات والعينات	تمثيل أفضل لكل الفئات والظروف	تجنب الاعتماد على منطقة واحدة أو قناة واحدة لجمع البيانات
تحليل البيانات قبل التدريب	اكتشاف التمثيل الناقص أو الشاذ لفئات معينة	فحص التوزيع، النسب، العلاقات بين المتغيرات
قياس العدالة عبر المجموعات الفرعية	ضمان أن النموذج لا يظلم فئة دون أخرى	عدم الاعتماد على "دقة عامة" فقط
مراجعة القرارات من فريق متعدد التخصصات	اكتشاف مشكلات لا يلاحظها فريق تقني فقط	إشراك مختصين في المجال المستهدف (طب، تعليم، قانون...)
توثيق التحيزات المعروفة والاعتراف بها	بناء ثقة وشفافية مع المستخدمين وأصحاب القرار	تحويل التحيز غير المرئي إلى تحيز معروف يمكن التحكم به

1.16 تحديد مصادر البيانات المناسبة والموثوقة لمشروعات الذكاء الاصطناعي

في أي مشروع ذكاء اصطناعي حقيقي لا يبدأ العمل من اختيار خوارزمية التعلم الآلي أو الحديث عن دقة النموذج بل يبدأ من سؤال بسيط في الظاهر عميق في الحقيقة من أين سنجلب البيانات التي سيتعلم منها النظام إذا كان الجواب غامضاً أو غير منضبط فسيتحول المشروع مع الوقت إلى نموذج يتنبأ بشكل جميل على الورق لكنه بعيد عن الواقع أما إذا تم اختيار مصادر البيانات بعناية فسيصبح النموذج أقرب إلى ما يحدث فعلاً في السوق أو في المستشفى أو في المؤسسة التعليمية ولهذا تعد عملية تحديد مصادر البيانات المناسبة والموثوقة خطوة أساسية لا تقل أهمية عن تصميم الخوارزمية نفسها

1.16.1 فهم صورة البيانات داخل المؤسسة قبل القفز إلى النماذج

مهندس البيانات في أي مؤسسة يبدأ عمله بمحاولة رسم خريطة للعالم الخفي الذي تعيش فيه البيانات داخل الشركة فهناك أنظمة تشغيلية مثل نظام نقاط البيع في المتجر أو نظام الحجز في شركة الطيران أو نظام شؤون الموظفين في مؤسسة كبيرة هذه الأنظمة تنتج بيانات بشكل يومي لكنها صممت في الأصل لتسهيل العمل وليس لبناء نماذج ذكاء اصطناعي ولذلك تكون البيانات موزعة بين جداول وقواعد مختلفة وأحياناً محفوظة في ملفات مستقلة أو تقارير دورية مهمة الخطوة الأولى هي فهم هذه البيئة ما الأنظمة الموجودة ما نوع البيانات التي تنتجها ما مدى دقتها ومن يستخدمها حالياً في اتخاذ القرار

من خلال هذا الفهم المبدئي يصبح من الممكن التعرف على الفجوات مثلاً قد تكتشف المؤسسة أنها تسجل مبيعاتها بدقة لكنها لا تحفظ أسباب أرباح المنتجات أو أن لديها بيانات جيدة عن حضور الموظفين لكنها لا تخزن معلومات عن المهارات والدورات التدريبية هذا النوع من الملاحظة يساعد لاحقاً في تحديد ما إذا كانت البيانات الموجودة تكفي لمشروع الذكاء الاصطناعي أم أن هناك حاجة إلى تصميم آلية جديدة لجمع بيانات إضافية

1.16.2 المقابلات مع أصحاب المصلحة واكتشاف المصادر المخفية

من أقوى الطرق العملية لاكتشاف مصادر البيانات التحدث المباشر مع أصحاب المصلحة داخل المؤسسة أصحاب المصلحة هنا لا يعني الإدارة العليا فقط بل يشمل كل من يتعامل مع البيانات في حياته


اليومية مدير المبيعات الذي يراجع تقارير فروعه موظف خدمة العملاء الذي يستخدم نظام الشكاوى محاسب الرواتب الذي يعمل على ملفات متكررة كل شهر هؤلاء الأشخاص يعرفون جيدا اين توجد الجداول المفيدة واي التقارير يعتمد عليها القرار واي النماذج في برنامج الجداول تمثل خبرة تراكت عبر سنوات

خلال هذه الحوارات يمكن لمهندس البيانات ان يطرح اسئلة من نوع ما التقارير الاكثر استخداما في عمالك اليومي ما الانظمة التي تثق في ارقامها وما الانظمة التي تشك في دقتها هل تحتفظ بنسخ خاصة بك على شكل ملفات اكسل او مستندات اضافية في كثير من الحالات يظهر ان جزءا مهما من البيانات يعيش في ما يسمى بيانات الظل وهي ملفات خاصة يحتفظ بها موظف او قسم كامل ولا تكون متاحة لبقية المؤسسة لكن فيها معلومات غنية عن الزبائن او المنتجات او العمليات اذا لم يتم كشف هذه المصادر ستبقى المعلومات ناقصة في مشروع الذكاء الاصطناعي مهما كانت الخوارزمية متقدمة

1.16.3 واجهات برمجة التطبيقات كمصادر بيانات موثوقة ومستمرة

في الانظمة الحديثة اصبحت واجهات برمجة التطبيقات **جسرا رئيسا** لتبادل البيانات بين الخدمات المختلفة داخل المؤسسة وخارجها واجهة برمجة التطبيقات هي ببساطة نقطة دخول رسمية يمكن للنظام من خلالها طلب بيانات محددة والحصول على استجابة منظمة في صورة **JSON** غالبا تكون هذه الواجهة موثقة في ملف او موقع يشرح عناوين الطلب والمعاملات الممكنة ونوع الاستجابة المتوقعة مع امثلة عملية

ميزة الاعتماد على واجهات البرمجة كمصدر للبيانات انها تقدم **تدفقا مستمرا ومحدثا** يمكن ربطه مباشرة بسير العمل لاستخراج البيانات بشكل آلي في اوقات محددة مثلا يمكن لنظام الذكاء الاصطناعي في متجر الكتروني ان يستدعي يوميا بيانات الطلبات الجديدة وحالة الشحن من واجهة نظام اللوجستيات الخارجي بدلا من ان يعتمد على ملف يرسله المورد مرة في الشهر هذا يقلل من التأخير في تحديث البيانات ويجعل النماذج اقرب لما يحدث في الواقع كما ان واجهات البرمجة تخضع عادة لرقابة مزود الخدمة مما يزيد من استقرارها وموثوقيتها مقارنة بملفات يدوية قد ينساها موظف او يعدلها دون تسجيل ذلك



1.16.4 البيانات العامة والمفتوحة كتكملة لمصادر المؤسسة الداخلية


كثير من مشاريع الذكاء الاصطناعي تحتاج الى معلومات ليست متوفرة داخل المؤسسة لان جمعها يتطلب قدرات حكومية او بحثية واسعة مثل بيانات التعداد السكاني او توزيع الدخل او معدلات التلوث او حركة المرور هنا يأتي دور البيانات العامة او المفتوحة التي تنشرها وزارات وهيئات رسمية او جامعات ومراكز بحثية

يمكن مثلا ان تستفيد شركة توصيل من بيانات رسمية عن كثافة السكان في احياء مختلفة لتفسير لماذا تتلقى عددا اكبر من الطلبات في مناطق معينة كما يمكن لمستشفى يرغب في بناء نموذج لتوقع ضغط الاشغال استخدام بيانات عامة عن انتشار امراض معينة في مواسم محددة لربطها مع بيانات المرضى عنده وتوقع الطلب على الاسرة والاجهزة هذا النوع من الدمج بين بيانات داخلية وخارجية يزيد من ثراء النموذج وقدرته على التقاط العوامل التي لا تراها المؤسسة من داخل جدرانها

1.16.5 المستودعات الداخلية ومستندات الملفات ومشكلة تشتت البيانات

على مستوى البنية الداخلية تخزن المؤسسات بياناتها في اشكال متنوعة فهناك **مستودع بيانات مركزي** ان وجد يجمع نسخا من اهم الجداول التحليلية وهناك قواعد بيانات تشغيلية خاصة بكل نظام على حدة مثل نظام الرواتب او نظام المخزون وهناك خادام ملفات تحتوي على ملفات اكسل ووثائق نصية ورسوم بيانية تعتمد عليها الاقسام المختلفة في عملها اليومي

هذا التشتت يخلق **تحديا** حقيقيا امام مشروع الذكاء الاصطناعي اذ قد يكون جزء من المعلومات اللازمة **في قاعدة بيانات رسمية** وجزء آخر في جدول اكسل خاص انشاء موظف قبل سنوات ولم يعد احد يعرف به لذلك يحتاج مهندس البيانات الى مراجعة وثائق الانظمة وسجلات الوصول والخرائط التقنية لمعرفة اين توجد النسخة الاكثر موثوقية من كل نوع من البيانات وهل هي محدثة ام مهجورة كما يجب الحذر من استخدام تقارير نهائية كمدخلات للتدريب اذا كانت قد مرت بسلسلة من الحسابات اليدوية التي لا يعرف احد تفاصيلها لان ذلك قد يدخل تحيزات غير مفهومة في النموذج



1.16.6 سجلات جرد البيانات وعقود البيانات كاساس للحوكمة

لتنظيم هذا العالم المتشعب من المصادر تتجه المؤسسات المتقدمة الى بناء ما يشبه **كتالوج بيانات** مؤسسي في هذا الكتالوج يتم تسجيل كل مصدر مهم مع معلومات اساسية مثل اسم قاعدة البيانات او الملف اسم مالك المصدر داخل المؤسسة القسم المسؤول الغرض الذي انشئ لاجله نوع البيانات المخزنة فيه فنيا او رقميا الفترة الزمنية التي تغطيها السجلات مستوى الحساسية هل يحتوي على بيانات شخصية ام لا والقيود القانونية او التنظيمية على استخدامه

في كثير من الحالات يدعم هذا الكتالوج بعقود بيانات رسمية خاصة بالمصادر الحساسة توضح من يحق له الوصول وكيف يمكن استخدام البيانات وهل يسمح باستخدامها في مشاريع ذكاء اصطناعي او فقط لاغراض التقارير الداخلية هذه العقود تحمي المؤسسة من النزاعات القانونية وتمنح فرق الذكاء الاصطناعي وضوحا منذ البداية حول ما يمكنهم فعله وما يجب تجنبه فلا يضطرون لاحقا الى اعادة بناء النموذج بسبب اكتشاف ان المصدر الذي اعتمدوا عليه لا يجوز استخدامه في هذا السياق

1.16.7 ادوات اكتشاف البيانات الآلية والحاجة الى خريطة حية للمصادر


مع توسع الانظمة وتعدد الفرق والتطبيقات يصبح من المستحيل تقريبا الاعتماد على ذاكرة الاشخاص وحدها لمعرفة جميع مصادر البيانات الموجودة لذلك ظهرت ادوات متخصصة في اكتشاف البيانات تعمل كعنصر ذكي يدور في بيئة المؤسسة ويفحص قواعد البيانات ومستودعات الملفات ويستطلع واجهات البرمجة ثم يبني فهرسا حيا لما يجده من جداول واعمدة وملفات

يستطيع مهندس البيانات عبر هذه الادوات ان يبحث مثلا عن كل الجداول التي تحتوي على حقول لها علاقة بعنوان السكن او عن كل الملفات التي تتضمن بيانات مبيعات خلال الثلاث سنوات الاخيرة فيظهر له فهرس يبين مكان كل مصدر وحجمه وتاريخ آخر تحديثه هذا يقلل بشكل كبير من احتمال تجاهل مصدر مهم او الاعتماد على مصدر قديم ويختصر الوقت اللازم للبحث اليدوي خصوصا في المؤسسات الكبيرة متعددة الفروع

1.16.8 الانتقال الى منصات البيانات السحابية كمركز موحد للمصادر

بعد التعرف على المصادر المختلفة وتقييمها غالبا ما يكون الخيار العملي هو نقل نسخ منظمة منها الى منصة بيانات مركزية تكون في كثير من الحالات بيئة سحابية مرنة في هذه المنصة يمكن بناء ما يسمى بحيرة بيانات لاستقبال البيانات الخام كما هي من الانظمة المختلفة ثم مستودع بيانات لتحويل جزء من هذه البيانات الى جداول منظمة جاهزة للتحليل وبناء النماذج

ميزة الاعتماد على السحابة انها تسمح بتوسيع السعة التخزينية وقوة المعالجة حسب الحاجة دون استثمار كبير في الاجهزة كما تسهل توزيع النسخ الاحتياطية عبر مراكز بيانات مختلفة مما يقلل مخاطر فقدان البيانات كما توفر السحابة ادوات مدمجة لادارة الصلاحيات وتسجيل كل عملية وصول او تعديل على الجداول مما يقوي جانب **الحوكمة والامن** بالنهاية يحصل فريق الذكاء الاصطناعي على منصة موحدة يمكنه من خلالها الوصول الى بيانات متسقة بدلا من التعامل مع عشرات الانظمة والملفات المتناثرة



1.16.9 معايير تقييم مدى ملائمة وموثوقية مصدر البيانات

تحديد المصدر لا يعني انه صالح تلقائياً لمشروع الذكاء الاصطناعي بل **يجب تقييمه وفق مجموعة من المعايير** من أهمها مدى **حدثة البيانات** هل يتم تحديثها باستمرار ام ان آخر تحديث كان قبل سنوات ومدى **اكتمال السجلات** هل يوجد عدد كبير من القيم المفقودة او **الاعمة الفارغة** ومدى دقتها هل تتطابق مع الواقع عند مقارنتها بمصادر اخرى مستقلة ومدى تغطيتها هل تشمل جميع الفئات التي يهتم المشروع دراستها ام تركز على شريحة معينة فقط

كما يجب النظر في **الجوانب القانونية والاخلاقية** هل يسمح القانون باستخدام هذه البيانات في الاغراض التي يستهدفها المشروع وهل تحتوي على معلومات شخصية يمكن ان تكشف عن هوية افراد اذا تم ربطها ببيانات اخرى **وما الاجراءات المطلوبة** لاختفاء الهوية او تقليل كمية البيانات الشخصية المجمعة الى الحد الضروري اضافة الى ذلك هناك جانب الكلفة فبعض المصادر قد تكون ممتازة لكنها مكلفة جدا في الاشتراك او في التخزين والمعالجة ويتعين موازنة الفائدة المتوقعة من النموذج مع التكلفة الكلية للحصول على البيانات واستخدامها عبر الزمن


1.16.10 مثال تطبيقي مبسط لتجميع مصادر بيانات مشروع توصية في متجر الكتروني

لتوضيح الفكرة تخيل مؤسسة اردنية تعمل في التجارة الالكترونية وتريد بناء نظام ذكاء اصطناعي يقترح منتجات مناسبة لكل زائر يعتمد مهندس البيانات في هذه المؤسسة على اكثر من نوع من المصادر الداخلية والخارجية فيبدأ اولا بمقابلة فريق المبيعات وخدمة العملاء ليعرف ما التقارير المتاحة حاليا عن سلوك الزبائن ثم يراجع قواعد بيانات المتجر حيث يجد جداول لطلبات الشراء وجداول لصفحات المنتجات التي زارها المستخدمون وجداول لحالة توفر المخزون بعد ذلك يكتشف من خلال وثائق النظام ان هناك واجهة برمجة تطبيقات توفر سجلا زمنيا لاحداث التصفح يمكن استخدامها لتجميع التسلسلات التي مر بها الزائر اثناء جلسته

لاحقا يقرر الفريق الاستفادة من بيانات عامة عن توزيع الاعمار ومستوى الدخل في المحافظات الاردنية لربطها مع عناوين الشحن فيرى مثلا ان بعض الفئات العمرية في مدينة معينة تميل الى شراء

فئة معينة من المنتجات بذلك تتكامل البيانات الداخلية مع البيانات الخارجية لتعطي صورة اغنى في النهاية يتم نقل نسخ منظمة من هذه المصادر الى منصة بيانات سحابية حيث تدمج الجداول ويزال التكرار وتخفى الهوية الشخصية بقدر الامكان ثم يستخدم فريق علم البيانات هذه المنصة لبناء نموذج التوصية وتقييمه ومع كل تحديث مستقبلي في البيانات تبقى عملية الجلب والتنظيف والدمج جاهزة لان مصدر البيانات قد تم تحديده وتوثيقه منذ البداية

بهذا المستوى من التفصيل يتبين ان تحديد مصادر البيانات المناسبة والموثوقة في مشروعات الذكاء الاصطناعي ليس خطوة سريعة في بداية المشروع بل هو عملية مستمرة تجمع بين الفهم العميق لعمل المؤسسة وبين المعرفة التقنية بطرق تخزين البيانات وواجهات البرمجة والسحابة ومعايير الحوكمة وكلما كان الطالب اكثر وعيا بهذه الجوانب كان قادرا في المستقبل على بناء حلول ذكاء اصطناعي اقرب الى الواقع اكثر عدالة واعمق اثرا في بيئة العمل التي ينضم اليها



تكامل البيانات الداخلية والخارجية لبناء حلول ذكاء اصطناعي واقعية وعادلة في بيئة العمل

منصة أساس التعليمية

مثال تطبيقي على تنظيف سلسلة زمنية ومعالجة القيم المفقودة

لتوضيح الفكرة تخيل ناديا رياضيا صغيرا قرر استخدام جهاز عد ذكي على باب الدخول لقياس عدد الاشخاص الذين يدخلون النادي كل ساعة الهدف من جمع هذه البيانات بناء نموذج بسيط يتنبأ بساعات الذروة من اجل تنظيم عدد المدربين وفتح او اغلاق بعض القاعات يفترض ان النادي يعمل من الاثنين الى الجمعة من الساعة الثامنة صباحا حتى العاشرة مساء وتم الاتفاق على تسجيل مجموع الزوار لكل ساعة لمدة ثمانية اسابيع لكن اجهزة انترنت الاشياء ليست مثالية فبعض القراءات تفشل في الوصول احيانا بسبب انقطاع الاتصال فتظهر في الجدول على شكل القيمة النصية NA بدلا من رقم

يمكن ان ننشئ بيانات تركيبية تشبه ما قد يحصل في الحياة الواقعية باستخدام بايثون كما في المثال التالي حيث نولد عددا عشوائيا من الزوار لكل ساعة مع اعتبار ان فترة المساء اكثر ازدحاما ونضع قيما مفقودة في نسبة صغيرة من الساعات تمثل فشل الحساس

```
import pandas as pd
import numpy as np

# اعداد معالم السلسلة الزمنية
np.random.seed(7)
days = pd.date_range(start="2023-09-04", periods=8*5, freq="B") # سبعة اسابيع عمل من الاثنين للجمعة
hours = pd.timedelta_range(start="8 hours", periods=15, freq="H") # من 8 صباحا الى 10 مساء

index = pd.MultiIndex.from_product([days, hours], names=["date", "time"])
data = pd.DataFrame(index=index, columns=["visitors"])

# توليد عدد الزوار مع اعتبار الإحجام المساء
for d in days:
    daily_counts = []
    for h in range(len(hours)):
        # ساعات المساء من 5 الى 9 اكثر ازدهارا
        if 9 <= h <= 13:
            count = np.random.randint(30, 60)
        else:
            count = np.random.randint(5, 30)
        # ادخل قيمة مفقودة بنسبة 15%
        if np.random.rand() < 0.15:
            daily_counts.append("NA")
        else:
            daily_counts.append(count)
    data.loc[(d,), "visitors"] = daily_counts

data = data.reset_index()
data["time"] = (pd.Timestamp("today").normalize() + data["time"]).dt.time
print(data.head(10))
```

لو نظرنا الى ناتج هذا الكود سنجد جدولا

يحتوي على تاريخ كل يوم وساعة محددة وعدد الزوار في تلك الساعة احيانا يظهر الرقم NA بدلا من قيمة رقمية وهذا يكسر استمرارية السلسلة ويمنع الكثير من خوارزميات التعلم الآلي من العمل عليها بشكل صحيح لذلك يجب اتخاذ قرار بشأن طريقة التعامل مع هذه القيم المفقودة

احد الخيارات البسيطة هو حذف كل الصفوف التي تحتوي على NA لكن هذا قد يؤدي الى فقدان جزء كبير من البيانات اذا كانت نسبة الفشل مرتفعة خيار آخر هو استبدال القيم المفقودة بمتوسط عدد الزوار في نفس الساعة لكن في ايام اخرى مثلا اذا كانت الساعة السابعة مساء مفقودة في يوم معين يمكن حساب متوسط الزوار عند السابعة مساء في بقية الايام واستخدامه كقيمة بديلة هذا يحافظ على نمط الذروة في المساء افضل من استخدام متوسط عام لكل اليوم

الكود التالي يوضح فكرة التعويض بمتوسط الساعة عبر جميع الايام

```

1 # رقمية NA الى NaN تحويل
2 data["visitors"] = pd.to_numeric(data["visitors"], errors="coerce")
3
4 # حساب متوسط الزوار لكل ساعة عبر جميع الايام
5 data["hour"] = pd.to_datetime(data["time"], format="%H:%M:%S").dt.hour
6 hourly_means = data.groupby("hour")["visitors"].mean()
7
8 # دالة تعويض: اذا كانت القيمة مفقودة نستبدلها بمتوسط تلك الساعة
9 def fill_with_hour_mean(row):
10     if pd.isna(row["visitors"]):
11         return hourly_means[row["hour"]]
12     return row["visitors"]
13
14 data["visitors"] = data.apply(fill_with_hour_mean, axis=1)
15
16 print(data.head(10))
17

```

بهذه الطريقة نحصل على سلسلة زمنية مكتملة الارقام بدون فراغات مع الحفاظ على فكرة وجود ساعات مزدحمة واخرى هادئة لكن يجب الانتباه الى ان اختيار طريقة التعويض يؤثر في شكل البيانات فمثلا استخدام آخر قيمة معروفة كما في اسلوب LOCF قد يمدد قمة الزحام لساعة اضافية لا يوجد فيها نفس العدد فعلا بينما استخدام متوسط الساعة قد يقلل من ارتفاع بعض القيم الحقيقية اذا كانت قمة اليوم اكبر بكثير من المعتاد لهذا السبب ينصح معظم المختصين بتجربة اكثر من تقنية تنظيف ومقارنة تأثيرها على النتائج قبل الاستقرار على واحدة منها فتنظيف البيانات ليس عملا آليا بالكامل بل يحتاج الى مزيج من العلم والفهم الجيد لسياق المشكلة التي نريد حلها بالذكاء الاصطناعي.

فيديوهات شرح :

https://www.youtube.com/watch?v=PMZ3dl5_kTI

<https://www.youtube.com/watch?v=ptqsPRRYdLE>

<https://www.youtube.com/watch?v=irDEWxDQAFg>

<https://www.youtube.com/watch?v=a3S-EfHokUw>

1.19 اختيار واستخدام هياكل وتنسيقات البيانات المناسبة في مشاريع الذكاء الاصطناعي

عندما يعمل نظام ذكاء اصطناعي في مؤسسة حقيقية لا تأتيه البيانات من مصدر واحد منظم وجميل بل تصله في صور عديدة مختلفة بحسب النظام الذي أنشأها وطريقة التخزين المتبعة فبعض البيانات تأتي من حساسات وأجهزة إنترنت الأشياء وبعضها من ملفات نصية أو جداول في قواعد بيانات وبعضها من واجهات برمجة تطبيقات على الويب لذلك يحتاج طالب هذا المجال إلى فهم الفكرة الأساسية: نفس المعلومة يمكن تمثيلها بهياكل وتنسيقات كثيرة وكل اختيار يؤثر في طريقة الالتقاط والتخزين والمعالجة داخل المشروع

الفقرة الاولى مصادر شائعة لبيانات مشاريع الذكاء الاصطناعي من اهم مصادر البيانات في التطبيقات الحديثة اجهزة إنترنت الاشياء مثل حساسات الحرارة والرطوبة والكاميرات والميكروفونات و اجهزة القياس في خطوط الانتاج والسيارات الذكية هذه الاجهزة ترسل تدفقات مستمرة من القراءات غالبا في صورة رسائل صغيرة تحتوي على وقت القياس وقيمتها وقد يتم تجميعها في ملفات او ارسالها مباشرة الى خادم مركزي عبر بروتوكولات متخصصة مصدر آخر هو الملفات المخزنة في أنظمة المؤسسة مثل ملفات جداول المبيعات او سجلات الحضور والانصراف او نتائج الاستبيانات هذه قد تكون على شكل ملفات نصية بسيطة او جداول بصيغة CSV او ملفات اكسل اما البيانات الأكثر تعقيدا فتخزن عادة في قواعد بيانات تقليدية (SQL) او قواعد بيانات حديثة (NoSQL) حسب طبيعة التطبيق

اضافة الى ذلك تعتمد تطبيقات كثيرة على واجهات برمجة تطبيقات على الويب توفرها خدمات خارجية مثل منصات الدفع والخراط والطقس فبدلا من تخزين كل شيء داخليا يرسل النظام طلبا الى الواجهة ويستقبل ردا في تنسيق منظم) غالبا (JSON ليستخدمة مباشرة في الخوارزميات

الفقرة الثانية تنسيقات الملفات النصية المنظمة وغير المنظمة

الملفات النصية غير المنظمة هي ابسط شكل للبيانات مثل مستندات تقارير مكتوبة او رسائل بريدية منسوخة الى ملف نصي هذه الملفات مفيدة اذا اردنا تحليل اللغة او استخراج افكار عامة لكنها لا تحتوي على بنية واضحة تسهل التعامل البرمجي لذلك تحتاج عادة الى مرحلة معالجة نصية قبل استخدامها في التعلم الآلي

في المقابل توجد تنسيقات نصية منظمة حيث يتم ترتيب البيانات على شكل حقول وصفوف او مفاتيح وقيم من اشهرها

١ ملفات CSV

ملف CSV هو جدول حيث يفصل بين الحقول رمز معين (غالبا الفاصلة) وتكون اول سطر فيه عناوين الاعمدة مثلا يمكن تخزين بيانات طلاب على النحو التالي

```
student_id,full_name,city,average_mark
S1001,"Omar Khalil","Amman",86.5
S1002,"Sara Nasser","Irbid",91.0
S1003,"Yousef Ali","Zarqa",78.0
```

سهولة هذا التنسيق تجعله منتشرا جدا لانه يفتح في برامج الجداول مباشرة ويمكن قراءته في بايثون او لغات اخرى بأدوات جاهزة لكنه يعاني من مشكلات مثل غياب صف العناوين في بعض الملفات او اختلاف رمز الفصل او وجود خلايا ناقصة لذلك يجب فحص الجودة قبل الاعتماد عليه

٢ تنسيق JSON

JSON يمثل البيانات على شكل ازواج (مفتاح : قيمة) يمكن تضمين بعضها داخل بعض لذلك يناسب جدا الهياكل المعقدة المستخدمة في تطبيقات الويب والهواتف مثال بسيط لسجل واحد لطالب

```
{
  "student_id": "S1001",
  "name": {
    "first": "Omar",
    "last": "Khalil"
  },
  "city": "Amman",
  "average_mark": 86.5,
  "courses": ["Math", "Physics", "Programming"]
}
```

هذا الشكل قريب من طريقة تمثيل القوائم والقواميس في بايثون مما يجعل تحميله ومعالجته امرا مباشرا باستخدام مكتبات معيارية كما يسمح بتمثيل قائمة من الكائنات في ملف واحد وهو التنسيق الشائع لردود واجهات برمجة التطبيقات على الويب

٣ تنسيق XML

XML يستخدم وسوما لاحاطة كل عنصر بمسمى واضح ويمكنه ايضا تمثيل هياكل متداخلة مثال مبسط لنفس بيانات الطالب

```
<student>
  <student_id>S1001</student_id>
  <first_name>Omar</first_name>
  <last_name>Khalil</last_name>
  <city>Amman</city>
  <average_mark>86.5</average_mark>
</student>
```

ميزة XML انه واضح للعين البشرية وسهل التوسع لكن معالجته قد تكون اثقل قليلا من JSON او CSV كما ان بعض تطبيقاته تعاني من نقاط ضعف امنية اذا لم تستخدم المكتبات بشكل صحيح لذلك يميل كثير من المطورين حاليا الى تفضيل JSON في تصميم واجهات البرمجة الحديثة

الفقرة الثالثة قواعد البيانات وهياكل التخزين الداخلية داخل الانظمة المتوسطة والكبيرة لا يكفي استخدام ملفات متفرقة بل تحتاج المؤسسة الى قواعد بيانات تنظم السجلات وتسمح بالبحث السريع والتحديث المتزامن قواعد بيانات SQL تعتمد على جداول مترابطة حيث يحدد مخطط ثابت للاعمدة (مثل رقم الطالب والاسم والتخصص) ويمنع ادخال قيم غير متوافقة وهذا يسهل ضمان سلامة البيانات ويجعل الاستعلام عنها بلغة موحدة في المقابل توفر قواعد بيانات NoSQL مرونة اكبر مع البيانات غير المتجانسة مثل سجلات نشاط المستخدم في موقع كبير او رسائل الدردشة حيث قد تختلف الحقول من سجل لآخر فمثلا يمكن تخزين كل رسالة على شكل وثيقة JSON كاملة دون فرض بنية موحدة على الجميع هذا مفيد لمشاريع الذكاء الاصطناعي التي تحتاج الى استيعاب بيانات متنوعة جدا من مصادر مختلفة لكن يتطلب تخطيطا جيدا لكيفية البحث والتصفية داخل هذه الوثائق

الفقرة الرابعة تأثير اختيار نوع الحقل وتمثيله على التحليل لا يقتصر اختيار تنسيق البيانات على شكل الملف فقط بل يشمل ايضا كيفية تمثيل كل حقل داخليا فمثلا رقم تعريف الطالب يمكن تخزينه كعدد صحيح او كسلسلة نصية اذا كان يحتوي على احرف او اصفار في البداية وفي معظم الحالات لا نحتاج الى اجراء عمليات حسابية على هذا الرقم لذلك يكون تمثيله كنص اكثر امانا حتى لا نفقد جزءا منه عند التحويل

في المقابل عمر الطالب او معدله يجب ان يخزن كقيمة رقمية (عدد صحيح او عشري) لان نماذج التعلم الالي ستحتاج الى مقارنته وحسابه ضمن معادلات مختلفة اذا خزناه كنص سيتطلب الامر تحويله في كل مرة وقد تظهر اخطاء اذا احتوت القيم على رموز غير رقمية لذلك يعد تصميم نوع كل حقل خطوة مهمة في تجهيز البيانات للمشروع

الفقرة الخامسة تحويل التنسيق واختيار الانسب للمشروع
في مشاريع حقيقية نادرا ما نجد ان كل شيء يأتي في نفس التنسيق بل غالبا ما يتعين على فريق البيانات تحويل المعلومات من شكل الى آخر مثلا قد تجمع استجابات استبيان من نظام يقدم ملفا بصيغة CSV بينما يصل سجل حضور الطلبة من واجهة برمجة تطبيقات تعيد JSON ويتم تخزين نتائج المعالجة النهائية في قاعدة بيانات SQL في هذه الحالة تصبح مهارة التحويل بين التنسيقات ضرورية؛ فيحوّل CSV الى جداول او الى كائنات JSON وتستخرج قيم معينة من XML لتخزينها في قاعدة البيانات وهكذا

اختيار التنسيق الانسب يعتمد على عدة عوامل منها حجم البيانات وسرعة الوصول المطلوبة وسهولة التكامل مع الانظمة الاخرى فملف CSV صغير قد يكون كافيا لمشروع تدريبي في مختبر مدرسة اما نظام متابعة طلاب على مستوى دولة فسيحتاج الى قاعدة بيانات كاملة مع واجهات برمجة قياسية لتبادل المعلومات بين الانظمة المختلفة المهم ان يدرك الطالب ان تنسيق البيانات ليس مجرد تفصيل تقني بل قرار يؤثر مباشرة في سهولة بناء نموذج الذكاء الاصطناعي ودقته وامانه على المدى البعيد

1.20 المزايا والعيوب والاستخدامات الشائعة لتنسيقات CSV و JSON و XML في مشاريع الذكاء الاصطناعي

يمكن تخزين ونقل البيانات بين الأنظمة بعدة تنسيقات، من أشهرها في عالم تطوير الأنظمة والذكاء الاصطناعي CSV و JSON و XML. لكل تنسيق منها نقاط قوة ونقاط ضعف، كما أن لكل واحد منها مواقف يكون هو الاختيار الأنسب فيها. فهم هذه الفروق يساعد الطالب على اختيار الشكل المناسب للبيانات عند تصميم مشروع ذكاء اصطناعي أو عند تجهيز البيانات للتدريب.

1.20.1 تنسيق CSV

تنسيق CSV هو أبسط الأشكال المنظمة للبيانات النصية، حيث تمثل كل سطر سجلا واحدا (مثل صف في جدول)، وتفصل الحقول داخل السطر بعلامة فاصلة (غالبا فاصلة او فاصلة منقوطة حسب الإعدادات).

من مميزات تنسيق CSV

في الغالب يكون خفيف الحجم وسهل القراءة والكتابة؛ يمكن فتحه مباشرة في برامج الجداول مثل اكسل أو ليبر أوفيس، كما يمكن تحميله بسهولة في لغات البرمجة المختلفة. يبسط التعامل مع البيانات الجدولية مثل سجلات المبيعات، درجات الطلبة، بيانات الحضور، حيث يكون كل صف حالة، وكل عمود متغيرا واضحا. يصلح كثيرا لعمليات الاستيراد والتصدير بين قواعد البيانات وبرامج التحليل، لذلك يستخدم بكثرة لنقل البيانات من نظام إلى آخر أو لتبادل البيانات بين فريقين.

من عيوب ومشكلات CSV وتأثيرها على مشاريع الذكاء الاصطناعي

المشكلة الأولى: غياب صف العناوين أو عدم توقيده

في بعض الملفات لا يوجد صف يوضح أسماء الأعمدة، أو تكون الأسماء غير واضحة أو مختلفة بين ملف وآخر، مما يصعب فهم مدلول كل عمود عند بناء نموذج ذكاء اصطناعي. هذا قد يؤدي إلى استخدام الحقول بشكل خاطئ (مثلا الخلط بين عمودين متشابهين)، وبالتالي ينتج نموذج ضعيف أو مضلل.

المشكلة الثانية: قيم مفقودة وتنسيق غير متسق

قد تحتوي ملفات CSV على خلايا فارغة أو رموز مختلفة للدلالة على القيمة المفقودة (مثل NA أو - أو فراغ)، كما قد تختلف طريقة كتابة الأرقام (فاصلة عشرية، فاصلة آلاف). هذه الفوضى تتطلب تنظيفا إضافيا، وإذا لم تُعالج جيدا، يمكن أن تسبب أخطاء في الحساب أو في تحويل نوع الحقول، فيتعامل النموذج مع قيمة نصية على أنها رقم أو العكس.

المشكلة الثالثة: صعوبة تمثيل الهياكل المعقدة

CSV مناسب للبيانات الجدولية البسيطة، لكنه غير مريح عندما نحتاج إلى تمثيل بيانات متداخلة مثل قائمة مشتريات داخل كل سجل عميل، أو تاريخ أحداث متتابعة لكل مستخدم؛ حينها نضطر إلى حيل مثل استخدام فواصل داخل الخلية نفسها أو إنشاء جداول إضافية وربطها، مما يزيد من تعقيد المعالجة قبل تدريب النموذج.

من الاستخدامات الشائعة لتنسيق CSV

تخزين بيانات تجميعية عن المبيعات اليومية أو الشهرية لسلاسل المتاجر وتحميلها في أدوات التحليل. نقل بيانات نتائج اختبارات الطلبة من نظام مدرسة إلى نظام متابعة مركزي على مستوى المنطقة التعليمية.

تصدير بيانات مراقبة أجهزة (عدد أخطاء، عدد طلبات، متوسط زمن استجابة) من نظام خادم إلى فريق علم البيانات لتحليل الأداء وبناء نماذج تنبؤية للأعطال.

1.20.2 تنسيق JSON

JSON تنسيق يعتمد على فكرة المفتاح والقيمة، ويسمح بتمثيل هياكل متداخلة بسهولة (كائن يحتوي على كائنات وقوائم). انتشر بشكل واسع مع تطبيقات الويب والهواتف، وهو اليوم التنسيق الأهم لواجهات برمجة التطبيقات.

من مميزات تنسيق JSON

سهل القراءة للفرد وسهل التفسير للحاسب، وبنيته قريبة من القوائم والقواميس في لغات مثل بايثون، مما يسهل تحويله مباشرة إلى هياكل بيانات جاهزة للمعالجة. يدعم التداخل بشكل طبيعي؛ يمكن أن يحتوي الكائن على قائمة، وكل عنصر في القائمة كائن آخر، وهكذا، وهذا يناسب جدا بيانات المستخدمين، وسجلات التفاعل، ونتائج الخدمات المركبة. مناسب لتخزين بيانات غير متجانسة نسبيا؛ ليس من الضروري أن تحتوي جميع الكائنات على نفس المفاتيح، مما يعطي مرونة في تطوير الأنظمة تدريجيا.

من عيوب ومشكلات JSON وتأثيرها على مشاريع الذكاء الاصطناعي

المشكلة الأولى: عدم الاتساق في الهيكل بين السجلات

في بعض المصادر، تكون المفاتيح غير ثابتة بين الكائنات؛ سجل يحتوي على مفتاح معين وآخر لا يحتوي عليه. عند تجهيز هذه البيانات لنموذج تعلم آلي جدولي يجب تحويلها إلى جدول واضح الأعمدة، مما يتطلب قرارات مثل: هل نملأ الفراغ بقيمة افتراضية؟ هل نحذف السجلات الناقصة؟ سوء اتخاذ هذه

القرارات قد يسبب تحيزاً أو فقداناً لمعلومات مهمة.

المشكلة الثانية: زيادة الحجم وصعوبة الفحص اليدوي

ملفات JSON الكبيرة قد تكون ثقيلة ويصعب قراءتها بالعين، خاصة مع التداخل العميق، مما يجعل اكتشاف الأخطاء (مثل مفتاح مكتوب غلط أو نوع حقل مختلف عن المتوقع) أصعب؛ إذا لم تُفحص البنية بشكل آلي بأدوات تحقق، فقد تمر أخطاء بنيوية إلى مرحلة التدريب وتؤثر في النموذج.

المشكلة الثالثة: اختلاف الاتفاقيات بين واجهات البرمجة

كل واجهة برمجة قد تستخدم أسماء مفاتيح وترميز أنواع مختلفة؛ مثلاً حقل التاريخ قد يأتي كسلسلة بنمط معين، أو كقيمة زمنية بعدد الثواني، أو حقل منطقي على صورة 1/0 أو true/false. إذا لم يُوحّد هذا النوع عند جمع البيانات من أكثر من واجهة، ستظهر تعارضات في مجموعة البيانات، وقد يفشل النموذج في تفسير المتغيرات كما يجب.

من الاستخدامات الشائعة لتنسيق JSON

تخزين سجلات تفاعل المستخدمين مع تطبيق (صفحات تمت زيارتها، أزرار تم الضغط عليها، عمليات بحث) في أنظمة تحليلات تجربة المستخدم.

نقل بيانات أجهزة إنترنت الأشياء إلى خادم مركزي عبر بروتوكول HTTP، حيث يرسل كل جهاز قياسه في كائن JSON يحتوي على الوقت والقيمة ومعرف الجهاز.

تخزين بيانات جلسات المحادثة في روبوتات الدردشة، بما يشمل نص الرسائل، وما تعرفه النظام عن حالة المستخدم، لاستخدامها لاحقاً في تدريب نماذج حوارية أدكى.

1.20.3 تنسيق XML

XML لغة ترميز تعتمد على الوسوم (tags) لتحديد بداية ونهاية كل عنصر، ويمكن استخدامها لوصف بيانات منظمة بطريقة مرنة، وهي منتشرة في أنظمة قديمة ومتوسطة، وما زالت مستخدمة في بعض الخدمات الرسمية.

من مميزات تنسيق XML

مصمم ليكون واضحاً للبشر والآلات؛ كل عنصر محاط بوسم يدل على معناه، ويمكن إضافة سمات تصف خصائص إضافية.

يدعم مفهوم المخطط (Schema) وأدوات التحقق من الصحة، ما يسمح بضبط شكل البيانات المسموح بها، والتأكد من سلامة الملفات قبل استخدامها في الأنظمة.

يصلح لتمثيل هياكل معقدة أو شجرية، ويستخدم في ملفات التكوين (configuration) وفي تبادل البيانات بين أنظمة مؤسسية كبيرة.

من عيوب ومشكلات XML وتأثيرها على مشاريع الذكاء الاصطناعي

المشكلة الأولى: ثقل الحجم وكثرة الوسوم

XML يحتوي على وسوم متكررة تغلف كل عنصر، مما يزيد حجم الملف مقارنة بنفس البيانات في JSON أو CSV، وهذا يؤثر في زمن النقل والتخزين خاصة عند التعامل مع بيانات ضخمة، وقد يجعل مرحلة التحويل الأولية أبطأ.

المشكلة الثانية: تعقيد المعالجة البرمجية

مقارنة بـ JSON، يتطلب تحليل XML استخدام مكتبات أكثر تعقيداً والتعامل مع شجرة عناصر بدل بنية أبسط؛ هذا يزيد من احتمال الأخطاء عند استخراج القيم المطلوبة، خصوصاً إذا كان الملف يستخدم فضاءات أسماء (namespaces) أو وسوما مخصصة كثيرة. أي خطأ في استخراج الحقول قد يؤدي إلى إدخال بيانات ناقصة أو خاطئة في نموذج الذكاء الاصطناعي.

المشكلة الثالثة: مخاطر أمنية محتملة

بعض أشكال XML يمكن أن تُستغل إذا لم تُضبط المكتبات بشكل صحيح (مثل مشكلات الكيانات الخارجية)، مما قد يفتح ثغرات على النظام الذي يعالج هذه الملفات. في مشاريع الذكاء الاصطناعي التي تستقبل ملفات من أطراف خارجية، هذا الخطر يجب أن يؤخذ بجدية، وإلا قد يتعرض النظام لهجمات تؤثر في سلامة البيانات أو تـ availability الخدمة.

من الاستخدامات الشائعة لتنسيق XML

تبادل البيانات بين أنظمة حكومية أو مصرفية قديمة وحديثة، حيث ما زال XML معيارا لبعض البروتوكولات. تخزين ملفات تكوين لأنظمة كبيرة (مثل تعريف تقارير، أو إعدادات واجهات)، يمكن قراءتها وتعديلها آليا أو يدويا. تمثيل بيانات معقدة في تطبيقات نشر إلكتروني، مثل الكتب والمجلات، حيث يصف XML الهيكل المنطقي للنص (فصول، عناوين، فقرات) وليس فقط شكله.

1.20.4 مقارنة عامة بين التنسيقات الثلاثة واختيار الأنسب لمشاريع الذكاء الاصطناعي

يمكن النظر إلى CSV على أنه الأنسب عندما تكون البيانات جدولية بسيطة ويهملنا الحجم الخفيف والسرعة وسهولة الربط مع الجداول وقواعد البيانات التقليدية، لكنه يضعف عندما نحتاج إلى علاقات متداخلة أو معلومات هرمية JSON. في المقابل يلمع في التطبيقات التي تحتاج إلى تبادل بيانات معقدة بين خدمات الويب والتطبيقات، خاصة عندما يكون مصدر البيانات واجهات برمجة تطبيقات أو قواعد بيانات NoSQL؛ فهو متوازن بين قابلية القراءة ودعم الهياكل المركبة. أما XML فيظل خيارا مهما في بيئات مؤسسية تعتمد عليه بالفعل وفي الحالات التي نستفيد فيها من قوة مخططاته وأدوات التحقق من صحة البيانات رغم ثمن التعقيد والحجم الأكبر.

في جميع الأحوال، يعمل طالب الذكاء الاصطناعي بذكاء عندما لا ينظر إلى تنسيق البيانات كمسألة شكلية، بل كقرار يؤثر في سهولة جمع البيانات وتنظيفها وتحويلها إلى شكل جاهز للتدريب. فاختيار تنسيق غير مناسب قد يضيف الكثير من العمل في مرحلة ما قبل المعالجة، ويزيد احتمالات الأخطاء والتحيز، بينما اختيار تنسيق ملائم لطبيعة البيانات يختصر الوقت ويجعل بناء النموذج وتحسينه أكثر سلاسة وموثوقية.

منصة أساس التعليمية

مقارنة تنسيقات البيانات (CSV, JSON, XML) في مشاريع الذكاء الاصطناعي

أولاً: CSV (الجدولي البسيط)	ثانياً: JSON (الهرمي المرن)	ثالثاً: XML (المهيكل بالسوم)
المزايا: - خفيف وسهل - مثالي للبيانات الجدولية - سهولة النقل العيوب وتأثيرها على AI: - غياب/قوضى العناوين - قيم مفقودة - صعوبة تمثيل الهياكل المعقدة استخدامات شائعة: - تحليل مبيعات - درجات طلبة - سجلات أداء	المزايا: - سهولة القراءة والتفسير - دعم التداخل (Nesting) - مرونة في الهيكل العيوب وتأثيرها على AI: - عدم الاتساق في الهيكل - زيادة الحجم - اختلاف الاتفاقيات استخدامات شائعة: - تحليل سلوك المستخدم - بيانات IoT - روبوتات الدردشة	المزايا: - واضح (Self-descriptive) - دعم التحقق (Schema) - تمثيل هياكل معقدة العيوب وتأثيرها على AI: - ثقل الحجم (Verbosity) - تعقيد المعالجة البرمجية - مخاطر أمنية محتملة استخدامات شائعة: - أنظمة قديمة/حكومية - ملفات تكوين - نشر إلكتروني/NLP
اختيار التنسيق المناسب يسهل تجهيز البيانات ويحسن نتائج الذكاء الاصطناعي.	تأثير مباشر على جودة النموذج ووقت التدريب	الخلاصة: الاختيار الاستراتيجي السرعة والبساطة المرونة والتعقيد

1.21 حماية بيانات أنظمة الذكاء الاصطناعي واعداد مجموعات التدريب والتحقق والاختبار

1.21.1 حماية بيانات أنظمة الذكاء الاصطناعي وضمان استمرارية العمل

أنظمة الذكاء الاصطناعي تعتمد على البيانات كما يعتمد المحرك على الوقود لذلك لا يكفي جمع البيانات مرة واحدة ثم نسيانها بل **يجب حمايتها والمحافظة** على استمراريتها وجودتها مع مرور الوقت واي اهمال في هذا الجانب يمكن ان يؤدي اما الى **توقف النظام عن العمل او الى خروج قرارات خاطئة** **تمس المستخدمين والعملاء مباشرة**

من اهم الخطوات في هذا المجال **وضع خطة نسخ احتياطي** منتظم للبيانات فلا يكفي الاحتفاظ بنسخة واحدة على نفس الخادم بل من الافضل الاحتفاظ بنسخ في اماكن مختلفة وربما في بيئة سحابية مستقلة بحيث لو تعرض مركز البيانات الرئيس لحريق او عطل كهربائي او برمجية خبيثة يمكن استرجاع البيانات من نسخة اخرى في وقت معقول في المؤسسات المحترفة يتم تحديد ما يسمى زمن الاستعادة المقبول وهو المدة القصوى التي يمكن للنظام ان يتوقف خلالها قبل ان تتأثر الاعمال بشكل خطير كما يتم تحديد الفترة الزمنية القصوى المسموح فيها بفقد بيانات جديدة منذ آخر نسخة احتياطية لكي يختار الفريق بين النسخ اليومي او كل ساعة او في نهاية الاسبوع حسب حساسية النظام

1.21.2 تعزيز الامن السبراني حول البيانات والنماذج

البيانات التي تغذي الذكاء الاصطناعي غالبا ما تحتوي على **معلومات حساسة** عن اشخاص او شركات او معاملات مالية لذلك تجذب انتباه المهاجمين الذين يسعون اما لسرقتها وبيعها او لتخريبها وتعديلها لذا تحتاج المؤسسة الى طبقات حماية متعددة تبدأ من جدار ناري مضبوط يمنع الاتصالات غير المصرح بها مرورا بنظام ادارة صلاحيات يمنح كل مستخدم ادنى قدر ممكن من الوصول وحتى تشفير قواعد البيانات وهي في حالة السكون وتشفير الاتصال بين الخوادم والتطبيقات باستخدام بروتوكولات أمنة

ولا يتوقف الامر عند البنية التحتية بل يشمل **الاجهزة الشخصية للعاملين** ايضا فحوادث كثيرة حدثت لان ملفا حساسا نزل الى حاسوب شخصي غير محمي او تم فتحه على شبكة عامة غير آمنة ولذلك توضع سياسات تلزم الموظفين بعدم تخزين بيانات العملاء على اجهزة خاصة وعدم مشاركة كلمات المرور او استخدام حساب واحد لعدة اشخاص كل هذه الاجراءات تهدف الى تقليل فرص تسلل غير مصرح به الى بيانات التدريب او سجلات الاستخدام

تعزيز الأمن السيبراني حول البيانات والنماذج




1.21.3 إدارة جودة البيانات والمراجعة الدورية

حتى لو كانت البيانات محفوظة بشكل آمن يمكن ان تفقد قيمتها بمرور الوقت **إذا لم تتم متابعة جودتها** فمثلا قد تتغير طريقة تسجيل الحقول في نظام معين او تظهر قيم جديدة لم تكن موجودة عند بداية المشروع مثل ظهور فئة جديدة لنوع منتج او تغيير في نظام الترميز البريدي اذا لم ينتبه فريق البيانات لهذه التغييرات ستبدأ قواعد البيانات في احتواء قيم غير متسقة مما يربك النماذج عند التدريب

لهذا السبب تقوم بعض المؤسسات بما **يشبه الفحص الطبي الدوري لبياناتها** حيث تحلل توزع القيم وتقارن بين فترات زمنية مختلفة للتأكد من عدم وجود انحرافات غير مبررة كما تفحص نسبة القيم المفقودة ونسبة التكرارات وتراجع سجلات التعديل لمعرفة ما اذا كان هناك نمط غير طبيعي في الدخول على الجداول الحساسة هذه المراجعات لا تحمي من الهجمات فقط بل تكشف ايضا الاخطاء البشرية العادية في ادخال البيانات قبل ان تنتشر وتؤثر في النماذج

ثالثاً: إدارة جودة البيانات والمراجعة الدورية



1.21.4 التدقيق الامني وخطط الاستجابة للحوادث


امن البيانات ليس اعدادا لمرة واحدة بل عملية مستمرة لهذا تلجأ المؤسسات **الى تدقيقات امنية دورية** يقوم بها فريق داخلي او شركة متخصصة تحاول ان تفكر بعقل المهاجم فتبحث عن نقاط الضعف في اعدادات الخوادم وكلمات المرور والتطبيقات التي تتعامل مع البيانات ثم تقدم تقريراً بالثغرات وخطوات اصلاحها

ومع الاعتراف بان نسبة الخطر **لا يمكن ان تصبح صفراً** يبقى ضروريا **وجود خطة استجابة للحوادث** **تحدد بدقة** ما يجب فعله عند اكتشاف خرق امني على سبيل المثال من المسؤول عن ايقاف النظام مؤقتا ومن يتولى تحليل سبب الاختراق ومن يتواصل مع الادارة العليا والجهات الرقابية ومن يخطر الاشخاص الذين ربما تأثرت بياناتهم هذه الخطة يجب ان تكون مكتوبة ومجربة مسبقا حتى لا يسود الارتباك في اللحظة الحرجة


منصة أساس التعليمية

رابعاً: التدقيق الأمني وخطط الاستجابة للحوادث

1. التدقيق الأمني الدوري (الجانب الاستباقي)



2. خطة الاستجابة للحوادث (الجانب التفاعلي)



خطة مكتوبة ومجربة مسبقاً لتجنب الارتباك

1.21.5 التعامل مع الهجمات العدائية على نماذج التعلم الآلي

نوع خاص من المخاطر في سياق الذكاء الاصطناعي هو محاولة **تسميم بيانات** التدريب بحيث يحقن مهاجم سجلات **تبدو طبيعية لكنها مصممة لجعل النموذج** يأخذ قرارات خاطئة في ظروف معينة مثل قبول معاملات مزيفة أو تصنيف رسائل احتيالية على أنها سليمة ولهذا ظهرت أدوات في مجال التعلم الآلي العدائي تساعد على فحص مجموعات البيانات بحثاً عن أنماط غير منطقية أو تغييرات مفاجئة في توزيع القيم كما يمكنها اختبار النموذج بهجمات تجريبية لمعرفة مدى قدرته على مقاومة التلاعب

1.21.6 اختيار وإعداد مجموعات التدريب والتحقق والاختبار

بعد أن تتوفر بيئة آمنة نسبياً للبيانات يأتي دور المرحلة العلمية التي يتم فيها اختيار وتشكيل مجموعات البيانات التي **سيتعلم منها النموذج** ويقاس عليها **أدائه** هنا يكون التركيز **على جودة البيانات** من حيث اكتمالها وتمثيلها للواقع وتوازنها بين الفئات المختلفة

في البداية يتم تشكيل مجموعة التدريب **وهي أكبر جزء من البيانات** وتستخدم لتعليم النموذج الأنماط الأساسية في المشكلة ثم تنشأ مجموعة تحقق مستقلة نسبياً تستخدم في أثناء التدريب لضبط معاملات النموذج مثل عدد الطبقات أو سرعة التعلم واختيار أفضل بنية دون المساس ببيانات الاختبار وأخيراً يحتفظ بجزء من البيانات لم يره النموذج قط يسمى مجموعة الاختبار وتستخدم بعد الانتهاء من التدريب لتقدير أداء النموذج الحقيقي على بيانات جديدة تشبه ما سيواجهه في الواقع

اختيار هذه المجموعات ليست عملية عشوائية كاملة بل يجب أن يراعى فيها أن تمثل كل مجموعة **توزيع الفئات نفسه** قدر الامكان فلو كانت بيانات مشروع ما تحتوي على عشرين في المئة من الحالات التي تمثل فئة معينة وثمانين في المئة تمثل فئة أخرى فيجب أن تبقى هذه النسب قريبة في مجموعات التدريب والتحقق والاختبار أما إذا تم اختيار بيانات الاختبار من فترة زمنية مختلفة تماماً أو من نوع حالات مميز فسوف نحصل على تقدير غير عادل لأداء النموذج وقد نظن أنه ضعيف جداً أو ممتاز جداً بينما الحقيقة في مكان آخر



1.21.7 اختيار البيانات وتقليل التحيز واحترام الخصوصية

عند اختيار البيانات لمجموعة التدريب يجب التفكير في سؤالين في الوقت نفسه هل هذه البيانات تمثل الواقع الذي أريد للنموذج أن يعمل فيه وهل جمع هذه البيانات واستخدامها يحترم حقوق الأشخاص الذين تظهر معلوماتهم فيها على سبيل المثال إذا كان الهدف بناء نموذج يساعد جامعة ما على التنبؤ بالطلاب على تخصص معين في السنوات المقبلة فلا بد من جمع بيانات من عدة افواج ودفعات ومن طلاب من مناطق مختلفة وخلفيات مدرسية متعددة وليس من كلية واحدة أو مدينة واحدة فقط

في الوقت نفسه يجب تجنب تخزين معلومات شخصية لا حاجة لها مثل اسم الطالب الكامل أو رقم هاتفه إذا كان النموذج يحتاج فقط إلى نوع المدرسة والمنطقة الجغرافية والدرجات العامة فوجود حقول إضافية يزيد من مخاطر الخصوصية دون أن يقدم فائدة حقيقية للمشروع لذلك يعد تقليل البيانات المجمعة إلى الحد المناسب مبدأ أخلاقياً وتقنياً في آن واحد

1.21.8 اعداد البيانات وتحويلها الى ميزات مناسبة


بعد اختيار السجلات المناسبة تبدأ عملية التطهير والتحويل فيتم البحث عن القيم المفقودة ومعرفة سببها هل هي ناتجة عن خلل في جمع البيانات أم أن المعلومة لم تكن مطلوبة اصلاً ثم يقرر الفريق هل يعوض هذه القيم بطريقة احصائية مثل المتوسط أو الوسيط أم يستبعد السجلات كاملة إذا كانت قليلة العدد كذلك يتم اكتشاف التكرارات التي قد تعطي وزناً مضاعفاً لبعض الحالات خاصة في بيانات التدريب

ثم تنتقل العملية من مستوى القيم الخام إلى مستوى الميزات الأوضح فمثلاً في مشروع يعتمد على معرفة سلوك العملاء قد لا يكون تاريخ الشراء كما هو مهما بقدر ما تكون المعلومات المشتقة منه مثل اليوم من الأسبوع أو الساعة أو الفصل الدراسي في السنة وكذلك يمكن تحويل العنوان النصي إلى متغيرات أبسط مثل المدينة ونوع المنطقة حضرية أم ريفية وكلما كانت الميزات أقرب إلى المشكلة التي نريد حلها كان النموذج أوضح وأبسط

جزء من هذا التحويل يكون في صورة تطبيع القيم الرقمية بحيث لا تأخذ المتغيرات ذات القيم الكبيرة جدا حجما اكبر من اللازم في الحسابات فمثلا اذا جمعنا بين دخل سنوي بوحدة الدنانير وبين درجة من واحد الى خمسة فقد يحتاج الدخلى الى اعادة تحجيم ليصبح فى مدى قريب من بقية المتغيرات حتى لا يفرض نفسه على النموذج

1.21.9 التحقق من صحة البيانات ومراجعة توزيعها

قبل تثبيت مجموعات التدريب والاختبار لابد من مراجعة منطقية لكل حقل هل نوع البيانات فيه صحيح هل التواريخ مرتبة بطريقة معقولة هل توجد اعمار خارج الحدود البشرية او قيم سالبة لا تنسجم مع



عن رضا الطلاب اذا تبين ان معظم الاجابات جاءت من تخصص واحد فهذا يعني ان النتيجة لا تعكس بقية التخصصات ويحتاج المشروع الى جمع بيانات اضافية لتحقيق توازن افضل

في المسائل الزمنية مثل التنبؤ بتأخر الرحلات الجوية او استهلاك الكهرباء يجب الانتباه الى طريقة تقسيم البيانات فلا يجوز خلط المستقبل بالماضي عند التدريب بل من الافضل استخدام السنوات السابقة للتدريب وترك فترة لاحقة للاختبار حتى نعرف كيف سيتصرف النموذج عندما يواجه زمنا جديدا لم يتدرب عليه وهذا يشبه اختبار طالب على اسئلة مختلفة عن تلك التي تدرب عليها في الحصة مع بقاء مستوى الصعوبة مشابها

1.21.10 منع تلوث بيانات الاختبار ومراقبة اداء النموذج بعد النشر

احد الاخطاء الشائعة في مشاريع الذكاء الاصطناعي هو ما يسمى **تلوث بيانات الاختبار** عندما تتسرب النتائج او بعض الامثلة من مجموعة الاختبار الى التدريب بشكل مباشر او غير مباشر فيبدو النموذج ممتازا في التقييم لكنه ينهار عند استخدامه على بيانات جديدة لذلك من الضروري عزل مجموعة الاختبار منذ البداية وعدم استخدامها في اتخاذ قرارات تتعلق بتصميم النموذج او اختيار معايير بل تبقى مخصصة لمرحلة التقييم النهائي فقط

بعد نشر النموذج في بيئة العمل الواقعية تستمر مهمة مراقبة ادائه فاذا تغيرت طبيعة البيانات مع الزمن كما يحدث في سلوك المسافرين او تغير قوانين المرور او ظهور منتجات جديدة في السوق قد تتدهور دقة النموذج تدريجيا هنا تعود اهمية كل ما سبق من ادارة جودة البيانات وامانها ووجود نسخ احتياطية وبنية مرنة تسمح باعادة تدريب النموذج على بيانات احدث مع الحفاظ على سجلات واضحة لما تم فعله حتى تبقى القرارات التي يتخذها النظام مفهومة وقابلة للتفسير امام الادارة والمستخدمين والجهات الرقابية

بهذا الفهم الشامل يدرك الطالب ان حماية البيانات الجيدة واختيار مجموعات التدريب والتحقق والاختبار بعناية ليست مجرد خطوات تحضيرية بل هي قلب نجاح مشاريع الذكاء الاصطناعي ودعامتها الرئيسية في الدقة والعدالة والموثوقية

فيديوهات شرح :

<https://www.youtube.com/watch?v=lzMBZSvyDNk>

<https://www.youtube.com/watch?v=-qj-yGbmpQA>

<https://www.youtube.com/watch?v=WJg3zykqxDg>

<https://www.youtube.com/watch?v=vVp0stplm2U>

المراجع (References)

1. Russell, S., & Norvig, P. (2020). Artificial Intelligence: A Modern Approach (4th ed.). Pearson.
2. Provost, F., & Fawcett, T. (2013). Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly Media.
3. Barocas, S., Hardt, M., & Narayanan, A. (2019). Fairness and Machine Learning. FairMLBook.
4. Barocas, S., & Selbst, A. D. (2016). Big Data's Disparate Impact. California Law Review, 104(3), 671–732.
5. Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step Data Mining Guide.
6. National Institute of Standards and Technology (NIST). (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0).
7. European Union. (2016). General Data Protection Regulation (GDPR), Regulation (EU) 2016/679.

- ECMA International. (2017). ECMA-404: The JSON Data Interchange Syntax. .8
- W3C. (2008). Extensible Markup Language (XML) 1.0 (Fifth Edition). .9
- Shafranovich, Y. (2005). RFC 4180: Common Format and MIME Type for Comma-Separated Values (CSV) Files. .10
- IBM. What is ETL (Extract, Transform, Load)? IBM Documentation / IBM Cloud Docs. .11
- Coursera. What is the Internet of Things (IoT)? (Online article). .12
- Wikipedia. Open data. (Encyclopedia article). .13

